



UNIVERSITE D'ANTANANARIVO

ECOLE SUPERIEURE POLYTECHNIQUE



MENTION TELECOMMUNICATION

MEMOIRE

en vue de l'obtention
du **DIPLÔME de Licence**

Titre : Ingénieur

Domaine : Sciences de l'Ingénieur

Mention : Télécommunication

Parcours: Système et traitement d'information

*par : **MAHEFA Harinianja***

RECONNAISSANCE VOCALE

VOCAL NOTE

Soutenu le Vendredi **16 Juillet 2021** devant la Commission d'Examen composée de :

Président :

M. ANDRIAMIASY Zidora

Examineur :

M. RANDRIAMIHAJARISON Jimmy

Directeur de mémoire :

M. RANDRIARIJAONA Lucien Elino

REMERCIEMENTS

Je rends grâce à Dieu pour Son Amour et Sa Bonté, de m'avoir donné la force et la santé durant la réalisation de ce mémoire de fin d'étude.

Je tiens également à adresser mes vifs remerciements aux personnes suivantes sans qui ce travail de mémoire n'aurait pas pu être réalisé :

Monsieur RAKOTOSAONA Rijalalaina, Professeur titulaire, Professeur, Responsable du domaine de Sciences de l'ingénieur de l'ESPA.

Monsieur RAKOTONDRAINAHina Tahina Ezéchiél, Professeur et Chef de département de la filière Télécommunication à l'Ecole Supérieure Polytechnique d'Antananarivo.

Monsieur RANDRIARIJAONA Lucien Elino, directeur de ce mémoire qui malgré ses lourdes responsabilités m'a toujours prodigué ses conseils et ses critiques constructifs durant l'élaboration de ce travail. Je tiens à lui adresser toute ma gratitude.

Monsieur ANDRIAMIASY Zidora qui me fait l'honneur de présider le jury de ce mémoire.

Monsieur membre du jury, enseignant au sein du Département Télécommunications qui a accepté de juger mon travail à sa juste valeur : Monsieur RANDRIAMIHAJARISON Jimmy.

Mes vifs remerciements s'adressent également à tous les enseignants et personnels de l'Ecole Supérieure Polytechnique d'Antananarivo en général et à ceux du Département Télécommunication en particulier, sans leurs efforts notre formation n'aurait pas pu atteindre ce stade.

Je n'oublierai pas ma famille pour leur soutien bienveillant et leur encouragement, pour ce mémoire, comme en toutes circonstances ; en particulier mes parents pour leurs sacrifices durant ces longues années afin que je puisse arriver à ce niveau.

Je remercie également mes amis qui m'ont épaulé et tous ceux qui ont contribué de près ou de loin à l'élaboration de ce mémoire.

TABLE DES MATIERES

REMERCIEMENTS	2
NOTATIONS	6
INTRODUCTION GENERALE.....	8
CHAPITRE 1 PRÉLIMINAIRE	9
1.1 Introduction :	9
1.2 Qu'est-ce que la reconnaissance vocale ? [7] [14] [15]	9
1.3 Développement de la reconnaissance automatique de la parole : [1] [9]	10
1.4 Contexte actuel : [1]	11
1.4.1 Développement de la microélectronique :	11
1.4.2 Expansion des techniques de communication et interconnexion généralisée des systèmes informatisés :	12
1.4.3 Coordination des recherches et amélioration des performances des systèmes de traitement automatique de la parole :	13
1.5 Applications de la reconnaissance vocale : [1] [5] [6]	15
1.5.1 Inspection, contrôle ou saisie de données :	15
1.5.2 Domotique : assistant-domestique électronique.....	16
1.5.3 Bureautique : systèmes de dictée ou d'entrée vocale de textes (EVT)	18
1.5.2 La Téléphonie :	18
1.5.4 La sécurité :	19
1.5.5 La géolocalisation :	19
1.6 Conclusion :	20
CHAPITRE 2 BASES DE LA RECONNAISSANCE VOCALE	21
2.1 Introduction :	21
2.2 Notion de la parole : [1] [2] [3] [10]	21
2.2.1 Point de vue populaire :	21
2.2.2 Définition technique :	21
2.2.3 La perception de la parole :	23

2.2.4 Spécificités de la parole :	24
2.3 Les étapes de la reconnaissance vocale : [8] [11] [12].....	30
2.3.1 La reconnaissance :	31
2.3.2 La synthèse ou Text To Speech (TTS) :.....	35
2.4 Les systèmes de reconnaissances vocales : [4] [13] [14]	36
2.4.1 Les systèmes de commandes vocales :.....	36
2.4.2 Les systèmes de dictée :	37
2.5 Les systèmes de dictée continue : théorie et technologie : [4] [13]	38
2.5.1 Le modèle acoustique :.....	39
2.5.2 Le modèle linguistique :.....	40
2.6 L'état actuel et l'avenir de la technologie : [4]	43
2.7 Conclusion :.....	44
CHAPITRE 3 APPLICATION VOCALE NOTE	45
3.1 Introduction :	45
3.2 Cahier de charge :.....	45
3.3 Choix des outils :.....	45
3.3.1 Pourquoi le langage Python ?	45
3.3.2 Sublime Text :	46
3.3.3 Pourquoi Pocketsphinx ?	47
3.4 Mode d'emploi :	47
3.4.1 Initiation :	47
3.4.2 Traitement de texte :.....	48
3.4.3 Commande et reconnaissance vocale :.....	52
3.5 Implémentation de la reconnaissance vocale :	56
3.5.1 À propos de la bibliothèque de reconnaissance vocale Pocketsphinx :	56
3.5.2 Les configurations des programmes pocketsphinx	56
3.5.3 La reconnaissance en temps réel de pocketsphinx ou LiveSpeech :	61

3.6 Conclusion :.....	64
CONCLUSION GENERALE	65
ANNEXES	66
1. Code source de classe reconnaissance vocale : pocketsphinx_inmic.py.....	66
2. Code source de la classe de queue : nonblock_queue.py	67
3. Code source la classe d'arrêt de traitement : stoppablethread.py.....	67
4. Code source principal de l'application : main.py.....	68
BIBLIOGRAPHIE	73
RENSEIGNEMENTS	75
RESUME.....	76
ABSTRACT	76

NOTATIONS ET ABREVIATIONS

Notations :

A :	Signal Acoustique enregistré
M :	Messages hypothétiques à comparer à A
$\bar{M}$:	Séquence de mots avec la plus haute correspondance à A
$P(M/A)$:	Probabilité que M correspond à A
$P(A/M)$:	Probabilité de validation de la prononciation de M à travers A
$P(M)$:	Probabilité d'énonciation d'un M
$P(A)$:	Probabilité du meilleur A

Abréviations :

ADSR	Asymmetrical Digital Subscriber
ASR	Automatic Speech Recognition
ASU	Automatic Speech Understanding
COCOSDA Assessment	Coordinating Committee on Speech Databases and Speech I/O Systems
DARPA	Defense Advanced Research Project Agency
Dict	Dictionary
ELRA	European Language Resources
GPRS	General Packet Radio Service
GPS	Global Positioning Satellite System
GSM	Global System for Mobile Communications
Hmm	Hidden Markov acoustic Models
HPC	Handled PC

IBM	International Business Machines
IHM	Interface Homme-Machine
LDC	Linguistic Data Consortium
Lm	Language model
LRE	Linguistic Research Engineering
NLP	Natural Language Processing
PDA	Personal Digital Assistant
PC	Personal Computer
RSI	Repetitive Strain Injury
SAM	Multilingual Speech and Methodology
STT	Speech to Text
TIDE	Telematics for the Integration of Disabled and Elderly
TMS	Troubles Musculo-Squelettiques
UMTS	Universal Mobile Telecommunications System
WAP	Wireless Application Protocol
WJS	Wall Street Journal
ATIS	Air Travel Information Services

INTRODUCTION GENERALE

Au début, plus précisément à l'époque où les premiers ordinateurs ont vu le jour, beaucoup de nos technologies actuelles étaient encore impossibles à réaliser, certains, dont le concept même était inconcevable. Ce fut le cas pour la reconnaissance vocale, car ce domaine, à l'époque, n'était encore qu'une superposition de plusieurs théories de différents chercheurs. La reconnaissance vocale, le fait de commander son ordinateur par moyen de la voix uniquement était vu comme un « rêve » inatteignable. Mais cela sans compter le progrès fulgurant de la numérique durant les deux décennies qui s'en est suivi.

Peu après l'innovation du numérique, de nombreux chercheurs ont commencé à se pencher principalement sur le domaine de la reconnaissance vocale, et ont, pendant plusieurs années, tenté d'établir des théories possibles sur la réalisation d'un programme de reconnaissance vocale pour les ordinateurs. Et leur travail a bien porté ses fruits, car de nos jours, ce domaine est déjà présent partout dans le monde à travers la technologie numérique qui est, aujourd'hui, au sommet de son évolution actuelle. De nombreux programmes de reconnaissance vocale ont, alors, vu le jour comme Alexa, Google (de Google) et Cortana (de Microsoft) ; des programmes qui, en ce moment même, sont en constante évolution pour pouvoir répondre plus efficacement aux besoins des utilisateurs.

Nous, les humains, n'avons pas beaucoup de difficultés pour reconnaître la voix et les mots de quelqu'un de notre entourage, nous comprenons parfaitement ce que ce nous dit. Mais qu'en est-il des ordinateurs ? Est-ce qu'une machine serait capable de faire de même et de reconnaître les mots de son utilisateur ? Grâce à la « reconnaissance vocale », cela est tout à fait possible et le but de cet ouvrage est, justement, de nous montrer cela en trois chapitres. Le premier chapitre introduira de façon générale la notion de « reconnaissance vocale », puis au second chapitre, nous voir quelques phases théoriques de la reconnaissance vocale.

Et enfin, le troisième chapitre consistera à la réalisation d'une application de reconnaissance vocale dont nous développerons en détail le fonctionnement et tous les outils nécessaires à sa création.

CHAPITRE 1

PRÉLIMINAIRE

1.1 Introduction :

Nous, les humains, depuis notre naissance percevons la voix et arrivons à distinguer une voix d'une personne de celle d'une autre personne. Notre expérience depuis ce moment, nous permet de savoir si une voix est aiguë, grave ou puissante, faible ou encore féminine ou masculine. Les spécificités de la voix et notre habitude à l'entendre très fréquemment aiguisent notre ouïe à pouvoir distinguer celle-ci à d'autres voix que nous entendons. Par contre, pour les ordinateurs ou d'autres machines programmées, il leur est impossible de réaliser cet exploit sans la reconnaissance vocale.

1.2 Qu'est-ce que la reconnaissance vocale ? [7] [14] [15]

Tout d'abord, la reconnaissance est plutôt connue par l'ensemble des ingénieurs comme « Reconnaissance automatique de la parole » ou bien « Automatic Speech recognition » alias ASR pour les plus habitués. L'ASR est un système matériel et logiciel qui permet de capter le son de la voix et d'identifier les mots prononcés. Il s'agit donc d'un système informatique qui permet d'analyser la parole captée au moyen d'un microphone pour la transcrire sous la forme d'un texte exploitable par une machine. L'ASU ou « Automatic speech understanding » étend cette objective et vise la compréhension de phrases entières au lieu de simples mots.




Figure 1.01 Représentation du processus de reconnaissance vocale

Rangée parmi les techniques de « traitement de la parole », la reconnaissance de la parole y rejoint la synthèse de la parole, l'identification du locuteur ou la vérification du locuteur. Des domaines en plein essor tant dans les laboratoires de recherches que dans nos produits

technologiques de tous les jours. L'ensemble de ces techniques permettent notamment de réaliser des interfaces vocales, c'est-à-dire, des interfaces Homme-machine (IHM) où l'interaction se fait à la voix.

De ce fait, la reconnaissance vocale transforme les voix enregistrées en séquence de mots, permet à la machine d'identifier celui qui a parlé, d'identifier ce que ce dernier a dicté et de déterminer des aspects paralinguistiques comme : le timing, l'intonation, la qualité de la voix.

La reconnaissance de la parole doit son existence à divers pans de la science. Nous pouvons citer en vrac, le traitement automatique des langues, la linguistique, le traitement du signal, les réseaux neuronaux, l'intelligence artificielle, etc.

Or, cet acte de parler à un objet n'est pas anodin et reste encore loin d'être résolu.

1.3 Développement de la reconnaissance automatique de la parole : [1] [9]

Ces trente dernières années ont été témoin d'une évolution impressionnante dans le développement du traitement automatique de la parole. D'un système de reconnaissance, le VIP100, premier à être commercialisé par Thershold Technology Inc. en 1972, qui était capable de reconnaître une centaine de mots isolés, après une phase d'apprentissage longue et fastidieuse, eu qui avait un encombrement d'un mètre cube environ, on est passé à des systèmes adaptatifs, intégrés dans les postes de travail et reconnaissant un vocabulaire pratiquement illimité.

À la fin des années 1970, avec l'apparition de la microélectronique, les premiers résultats obtenus en traitement automatique de la parole étaient si prometteurs qu'ils avaient suscité d'audacieuses prévisions : un journaliste s'était risqué à prédire la disparition totale en 1986 des machines à écrire à clavier et leur remplacement par une interface entièrement vocale. Si on est loin de constater une telle réalité, il faut cependant souligner les changements survenus notamment depuis 1993, date à laquelle le premier système de reconnaissance de parole continue fonctionnant pratiquement en temps réel a été présenté pour la langue allemande par Philips lors de la Conférence d'EUROSPEECH à Berlin. Depuis cette date, une vive compétition entre les équipes de recherches et les industries a conduit à une chute spectaculaire du prix des produits proposés et à une amélioration notable tant leur performance que de leurs modalités d'utilisation. Les technologies vocales sont dorénavant utilisées non seulement par les professionnels, mais également par le grand public : la multiplication des serveurs vocaux en est un exemple.

Avec l'avènement d'Internet qui permet à une personne de n'importe quel point dans le monde d'avoir accès à n'importe quelle base de données distante, tout en communiquant avec plusieurs autres utilisateurs de ces mêmes sources d'information, la parole offre un mode d'interaction particulièrement naturel et efficace. Il convient donc de s'interroger sur la place que peuvent prendre les technologies vocales dans un tel contexte, que ce soit comme un seul mode de communication ou encore comme mode complémentaire à d'autres modes.

En effet, on a pris également conscience, depuis ces quinze dernières années, de la spécificité de la parole et précisé le rôle qu'elle peut dorénavant jouer dans une interaction multimodale complexe faisant intervenir ensemble plusieurs modes de perception et de production. De nombreux domaines d'applications peuvent ainsi être identifiés, dans lesquels la parole, soit secondée par le geste ou le regard, soit subordonnée à ces modes, est capable de répondre aux attentes de l'utilisateur de façon optimisée (Caelen & Coutaz, 1991).

1.4 Contexte actuel : [1]

Plusieurs facteurs concomitants favorisent actuellement la généralisation des technologies vocales dans les nouvelles interfaces.

1.4.1 Développement de la microélectronique :

Le développement rapide de la microélectronique conduit à une augmentation en puissance (qui double environ tous les deux ans selon la loi de Moore) des processeurs standards et des mémoires. De ce fait, les algorithmes de traitement du signal de la parole (reconnaissance et synthèse), gourmands en temps de calcul et de mémoire, fonctionnent maintenant sur des composants numériques de base et ne requièrent plus de carte ou de matériel spécialisé. Les systèmes à petit vocabulaire conçus par Dragon Systems, IBM, Philips, etc., peuvent ainsi être incorporés dans les PC, quelques fois directement dans le logiciel de traitement de textes, ainsi que dans les assistants numériques personnels (PDA : Personal Digital Assistant). Cela leur permet d'être diffusés à des millions d'exemplaires. Cette banalisation des logiciels de traitement du signal et de la parole a entraîné une diminution spectaculaire des coûts des produits.

Par ailleurs, la miniaturisation favorise l'informatique nomade et permet dès à présent l'intégration de la reconnaissance dans les téléphones portables. Grâce à l'expansion des

techniques de communication par satellite, des terminaux HPC (Handled PC), suffisamment compacte pour tenir dans la main, doivent allier les fonctions de téléphonie et d'accès à Internet, utilisation le GPS (Global Positioning Satellite System) pour déterminer la localisation d'un véhicule ou d'un individu. Il est même envisagé que l'interface soit diluée totalement dans l'environnement : comme l'indique le thème : « *The disappearing computer* », de l'appel d'offres des communautés européennes de mai 2000, les processeurs et prises de son peuvent alors être directement incorporés soit dans les murs des maisons, soit dans la tenue vestimentaire (*Wearable Computer*), tels le système Navigator de Carnegie Mellon University (CMU) et certains prototypes de France Télécom R&D.

1.4.2 Expansion des techniques de communication et interconnexion généralisée des systèmes informatisés :

En effet, les techniques de communication, notamment les réseaux informatiques et téléphoniques, ont suivi, à la fin des années 90, une croissance exponentielle, qu'il s'agisse du réseau Internet qui, avec la Toile, permet l'accès immédiat à des banques de données de textes, d'images et de parole réparties dans le monde, ou qu'il s'agisse des réseaux téléphoniques numériques et cellulaires, destinés tout d'abord aux professionnels et maintenant de plus en plus au grand public. Ce développement bénéficie directement de l'amélioration des techniques de traitement du signal (Codage, compression et multiplexage) permettant d'optimiser les liaisons (optiques ou par satellites).

La normalisation du réseau radio Itineris/GSM (Global System for Mobile Communications), bientôt remplacé par le GPRS (General Packet Radio Service) devrait permettre à celui-ci de couvrir la majeure partie du territoire français, en attendant le système de 3^e génération UMTS (Universal Mobile Telecommunication System), à l'horizon 2005. Grâce à des vitesses de transmission élevées (jusqu'à 2Mbits/s), le système UMTS rendra également possible le lancement de services multimédias. La croissance des téléphones portables est explosive en raison de la mise en place des réseaux de satellites en orbite basse : le nombre des abonnés de téléphones mobiles dépassait en janvier 2002 le cap des 900 millions dans le monde.

On assiste de fait à la mise en place d'un réseau d'interconnexion totale entre stations de travail, téléphones et postes de télévision, etc. Les nouveaux systèmes, notamment les Net Telephones, intègrent de multiples fonctionnalités grâce au protocole WAP (Wireless Application Protocol)

qui permet l'accès à la Toile à partir d'un téléphone portable, en faisant communiquer les normes utilisées à la fois par le GSM et l'Internet.

La reconnaissance de la parole dans ce contexte prend une importance accrue, du fait du clavier nécessairement réduit des téléphones portables et des assistants numériques personnels (PDA).

1.4.3 Coordination des recherches et amélioration des performances des systèmes de traitement automatique de la parole :

L'amélioration des performances des systèmes a été déterminante ces quinze dernières années : en effet en 1985, les systèmes étaient capables de reconnaître un locuteur prononçant en mots isolés, après apprentissage, un vocabulaire de quelques centaines de mots ; actuellement, les systèmes sont capables de reconnaître n'importe quel locuteur utilisant en parole continue un vocabulaire de plusieurs centaines de milliers de mots, voire illimités, pour peu que la prise de son soit contrôlée et que l'environnement sonore ne soit pas trop intrusif ; ou encore ils sont capables de conduire un dialogue avec un vocabulaire de quelques milliers de mots à travers le téléphone, sur un sujet bien défini (renseignements sur les horaires de train ou d'avion, par exemple). Ces avancées ne sont pas tant dues à une amélioration des connaissances (la plupart des algorithmes étaient connus dans les années 1970), qu'à l'organisation de campagnes d'évaluation systématiques. Ces campagnes ont pu naturellement être mises en place grâce au développement de la microélectronique qui favorisait le temps réel et la constitution de grandes bases de données, mais elles procèdent également d'une prise de conscience, par les spécialistes du domaine, de l'importance du *paradigme d'évaluation*. Ce paradigme, tout d'abord défini dans des programmes américains, est devenu central dans nombre de projets européens, aussi bien nationaux qu'internationaux.

Le programme lancé aux États-Unis en 1984 par la DARPA (Defence Advanced Research Project Agency ou Agence des projets de recherches avancées de la défense) sur le Traitement de la parole et du langage naturel (Speech and Natural Language) fut un des premiers à mettre en place des campagnes périodiques d'évaluation des systèmes et à encourager ainsi une comparaison objective de méthodes différentes. Les résultats obtenus lors de ces campagnes successives montrent bien une amélioration continue des performances au fil des années et une plus grande adaptabilité des logiciels.

Une telle organisation destinée à l'évaluation des systèmes suppose, outre en consensus préalable sur l'utilisation de méthodes et protocoles communs, la disponibilité de ressources et d'outils linguistiques identiques susceptibles de mesure de manière assez formelle les progrès accomplis. En effet, les approches les plus couramment utilisées, de nature stochastique (Modèle de Markov) ou neuromimétique (Mariani, 1990), nécessitent l'entraînement des systèmes sur de grands corpus de signal et de textes (Néel et al. 1996). Un effort a donc été engagé dans le cadre de ce même programme DARPA pour la constitution de grandes bases de données concernant différents domaines d'application : les corpus WJS (Wall Street Journal) et ATIS (Air Travel Information Services) en sont des exemples.

La diffusion de telles ressources linguistiques a été également facilitée par la création, aux États-Unis, d'un organisme spécifique, le LDC (Linguistic Data Consortium), qui a pour vocation de mieux coordonner la collecte et de veiller à la disponibilité des corpus (signal de parole et texte) sur le réseau de la Toile et sous forme de Cédéroms.

En Europe, dans le cadre des programmes ESPRIT et LRE (Linguistic Research Engineering), de nombreux programmes furent lancés dès 1988 par les communautés sur le thème de l'évaluation : l'un des premiers, le projet ESPRIT SAM/SAM-A (Multilingual Speech and Methodology), rassemblant plus de 30 partenaires industriels et universitaires avait pour objectif de définir des normes pour les systèmes de reconnaissance, de vérification du locuteur et de synthèse.

L'intérêt de ces multiples projets européens fut de placer directement les études dans un contexte multilingue et de privilégier des méthodologies indépendantes d'une langue donnée. L'un des résultats les plus marquants fut la création en février 1995 à Paris d'ELRA (European Language Resources Association) dotant la communauté scientifique européenne d'un organisme équivalent au LDC, qui permettait la collecte et la diffusion de corpus représentatif des diverses langues européennes. D'autres projets, tels qu'EUROCOSSDA, ont facilité des collaborations en relation avec le programme international COSSDA (Coordinating Committee on Speech Databases and Speech I/O Systems assessment).

Ces évaluations qui permettent de confronter les réponses d'un système à des corpus de références d'un système à des corpus de références ne mesurent bien évidemment qu'un aspect des performances du système (taux d'erreurs de reconnaissance, par exemple) et ne peuvent

être considérées comme suffisantes pour garantir une bonne acceptation de la part de l'utilisateur. Il est nécessaire également d'exécuter des tests systématiques en situation opérationnelle, tels que ceux menés par les opérateurs de télécommunications qui conçoivent, développent et diffusent des produits. Les évaluations des systèmes de reconnaissances sur site opérationnel ont permis un diagnostic précis des limites technologiques vocales et une meilleure perception des besoins réels des utilisateurs, ce qui a entraîné une meilleure adéquation des services proposés.

L'expérimentation en situation proche du réel est nécessairement plus coûteuse et comporte évidemment des limitations (le système visé n'existe pas encore ou du moins ne comporte pas toutes les fonctionnalités envisagées). Mais cette approche, même avec des prototypes simplifiés parce qu'en cours de développement, apporte des éléments précieux permettant de préciser les priorités et d'orienter ainsi les recherches ultérieures.

1.5 Applications de la reconnaissance vocale : [1] [5] [6]

Étant donné que la parole, aisément utilisée en superposition à d'autres modes de communication, libère la vue et les mouvements, il est possible d'identifier plusieurs domaines d'application dans lesquels notamment plusieurs tâches doivent être effectuées en parallèle : domaine industriel avec les systèmes de commande (manipulation d'objets, d'automates...) ou saisie de données (lors de contrôle de processus, d'observations microscopiques, d'inspection de matériels, par exemple), domotique. À ces domaines, il convient d'ajouter la bureautique avec les systèmes de dictée, la formation professionnelle ou individualisée et, plus récemment, la traduction automatique. Dans la majeure partie des cas, les produits sont commercialisés depuis de nombreuses années et utilisés couramment. En revanche, en ce qui concerne la formation et la traduction, les produits sont commercialisés depuis de nombreuses années et utilisés couramment. En revanche, en ce qui concerne la formation et la traduction, les études sont encore le plus souvent au stade de projets de recherche ou de réalisation de prototypes en cours d'évaluation.

1.5.1 Inspection, contrôle ou saisie de données :

La fonctionnalité mains libres/vue libre que procure une interface vocale est là essentielle. Plusieurs systèmes fonctionnent dans beaucoup de pays, notamment dans le domaine militaire pour la maintenance des avions : dans ce cas un système portable ou vestimentaire est utilisé.

À titre d'exemples opérationnels, nous pouvons citer Voice Scribe de Dragons Systems qui a été intégré par Auralog, en France dès 1988, pour le contrôle de qualité des moteurs d'avion.

Plus récemment, un système portable Talkman de Vocollect a été évalué et mis en service à la SNCF (Société nationale des chemins de fer français) pour des opérations itinérantes. Ces opérateurs effectuent des relevés d'information (à partir d'environ 1000 points de mesure) sur des organes de wagons SNFC pour déclencher le passage en révision. Les utilisateurs manipulent des outils et divers instruments de mesure lors de ces relevés ; ils interviennent dans des conditions dangereuses (sous les wagons, sur les toits, sur des échelles, etc.). Les évaluations réalisées avec les opérateurs ont montré une large préférence pour la saisie vocale en comparaison de la saisie au clavier, dans la mesure où elle leur assure une plus grande sécurité. Ce système monolocuteur avec apprentissage, utilisant un vocabulaire de 150 mots, montre également de bonnes performances pour des utilisations en milieu industriel bruyé tel que les ateliers de réparation de la SNFC.

Toujours à la SNFC, le système MGPT (Module de gestion des protections travaux) en utilisation quotidienne permet aux agents de demander vocalement, dans un langage imposé par les normes de sécurité, l'autorisation d'effectuer des travaux sur des lignes ferroviaires. Le système de reconnaissance développé par Vecsys, en service depuis janvier 1997 sur la ligne Paris-Lille de France, est en cours de déploiement sur les autres régions.

1.5.2 Domotique : assistant-domestique électronique

Nous avons probablement tous déjà entendu parler de la « domotique », qui est, elle aussi, un domaine dont l'évolution avance très vite. Pour décrire la domotique de façon très simplifiée, c'est une branche de la technologie actuelle qui concerne l'application des commandes vocales sur un bâtiment entier, voir même l'environnement autour de l'utilisateur.

Par exemple, supposons qu'une maison est assez grande pour contenir trois étages. Étant au troisième étage, il serait fatigant de descendre au premier étage pour éteindre les lumières manuellement. Il suffirait, qu'en étant toujours au troisième étage, que nous puissions énoncer la commande : « éteindre les lumières du premier étage », pour que le programme éteigne d'elle-même les lumières sans que nous intervenions physiquement.




Figure 1.2 Processus de commande pour la domotique

Dans le domaine de la domotique, plusieurs systèmes de contrôle vocal d'environnement ont déjà été commercialisés, notamment aux États-Unis afin d'effectuer certaines commandes simples d'appareils : réglage du chauffage, orientation des volets, etc. Ces systèmes lorsqu'ils seront couplés à des caméras de capture d'environnement devraient permettre d'offrir dans le futur des services variés d'assistance dans la vie quotidienne.

Dès à présent, de nombreux systèmes de ce type viennent en aide aux personnes souffrant d'un handicap moteur :

En France, le système NEMO permet aux tétraplégiques de contrôler par la voix les objets de leur environnement (télévisions, volets, téléphone, etc.).

Le projet européen TIDE (Telematics for the Integration of Disabled and Elderly) HOME, vise à élaborer un dispositif de contrôle pour une grande variété d'appareils électroniques domestiques. Ce système est principalement destiné aux personnes âgées ou handicapées.

1.5.3 Bureautique : systèmes de dictée ou d'entrée vocale de textes (EVT)

En parlant d'entrée de textes, il est évident d'énoncer l'utilisation du clavier sur lequel nous tapons habituellement nos textes. Quand certaines tâches sont effectuées plus efficacement par les interfaces visuelles, la reconnaissance vocale, quant à elle, est une meilleure interface que le clavier dans les tâches où le langage spontané est utile, ou pour lesquelles les claviers ne sont pas appropriés. Nous sommes probablement d'accord pour dire que dicter est bien plus efficace et rapide que d'écrire quand il s'agit de saisir des informations importantes très rapidement.

Prenons par exemple qu'une réunion d'une très haute importance ait lieu et dont les discussions et les débats sont très nombreuses, mais dont chacune d'entre elles doit être notée due à l'importance cruciale des informations, nous savons que les machines possèdent une plus grande réactivité et une bien plus grande vitesse dans l'exécution des tâches, donc l'utilisation de machines pour enregistrer chacune de ces informations grâce à la reconnaissance vocale serait bien plus efficace et rapide que d'employer un secrétaire qui saisisse ces notes manuellement au clavier.

Outre le domaine du handicap moteur pour des personnes souffrant d'arthrose ou de TMS (Troubles musculo-squelettiques, suscités par des tâches répétitives, RSI en anglais pour Repetitive Strain Injury), l'une des premières applications de référence des systèmes de dictée à grands vocabulaires concernerait le domaine médical. En effet, la constitution de rapports médicaux, notamment en radiologie, est une tâche facilement automatisable dans la mesure où ceux-ci sont en général des documents très structurés utilisant un vocabulaire prédéfini. Une autre raison pour une telle automatisation est que l'introduction de l'entrée vocale, tout en permettant de faciliter la tâche des secrétaires, ne constitue pas un changement dans les habitudes du médecin puisque la reconnaissance est couplée à un dictaphone déjà couramment utilisé.

Actuellement, des besoins similaires ont été identifiés dans le domaine juridique, bancaire ou dans celui des assurances pour lesquels la création de documents/rapports représente une activité importante.

1.5.2 La Téléphonie :

Un domaine où la reconnaissance vocale tient toute sa place est bien la téléphonie. Par exemple, elle est présente dans les systèmes de dialogues dictés, comme pour la reconnaissance de « oui »

pour accepter les appels. Ou encore, dans la recherche d'informations d'avions ou de trains, et aussi dans les réponses automatiques.

1.5.4 La sécurité :

Quand nous parlons de la reconnaissance automatique de la parole, il est inévitable de parler de la notion de sécurité. Car grâce à un programme d'ASR suffisamment puissant et précis, la protection d'informations personnelles ou de données importantes serait plus efficace. Car si un programme est capable d'identifier un utilisateur autorisé de façon très précise, l'accès illégal à l'information protégée serait presque impossible pour les personnes non autorisées.

Par exemple, il est courant que les centres de données ou Data Center d'une entreprise soient très hautement sécurisés pour que les informations qu'ils contiennent ne tombent pas dans de mauvaises mains. En effet, il n'est vraiment pas rare, que ces centres aient des coffres fermés à triples tours grâce à des matériaux spécifiques et qu'ils soient aussi équipés de caméras de surveillances de très haute qualité opérationnelles 24h/24 pour que la surveillance soit permanente. En ajoutant la reconnaissance vocale qui fait que seul le personnel autorisé peut s'identifier et avoir accès à ces informations et un mot de passe dicté à l'ordinateur pour confirmer l'identité du personnel, la sécurité au niveau de ces centres de données n'en serait que plus efficace.

Un autre exemple est la sécurité des comptes personnels de personnes sur les réseaux sociaux. Étant actuellement très répandu à travers le monde, le piratage de comptes personnels dans les réseaux sociaux n'est plus chose rare. Or, même les plus grandes entreprises mondiales effectuent certaines de leurs actions sur ces réseaux sociaux, il est donc normal penser à augmenter la sécurité de ces réseaux pour éviter des tragédies économiques pour ces entreprises. Implémenter une identification vocale pour chaque compte serait une solution efficace pour protéger ces comptes et ainsi ne pas perdre d'importantes données.

1.5.5 La géolocalisation :

Cela pourrait sembler étrange, mais la reconnaissance automatique de la parole peut effectivement servir dans la géolocalisation. La réponse à la question que nous nous posons, c'est que grâce à la reconnaissance vocale, la création d'assistants GPS devient possible. Il est vrai que dicter à son smartphone la position exacte où nous nous trouvons et lui dicter la destination pour qu'il puisse envisager les itinéraires les plus adéquats est bien plus pratique

que de se servir en permanence d'une interface manuelle surtout si nous sommes mouvement ou que nous soyons entrain de conduire un quelconque véhicule. Le processus se ferait en discutant avec le smartphone grâce à ce que l'on appelle « assistant vocal » pour rendre le programme GPS bien plus agréable.

Dans certaines applications, une interface multimodale qui combine la reconnaissance vocale et l'interface graphique est bien plus efficace qu'une interface graphique sans reconnaissance vocale.

1.6 Conclusion :

En guise de résumé avant de passer au chapitre suivant, il est à noter que la reconnaissance vocale est simplement un domaine qui, au fil des années, a accumulé des multitudes de recherches spécialisées et de théories de plusieurs ingénieurs compétents et qui vise à permettre aux programmes dans les machines ou ordinateurs de reconnaître une voix humaine et les mots ou phrases que ce dernier prononce, en tant que commande ou en tant que simple information. Dans le chapitre suivant, nous détaillerons les bases nécessaires à la reconnaissance vocale liées au programme que nous allons réaliser.

CHAPITRE 2

BASES DE LA RECONNAISSANCE VOCALE

2.1 Introduction :

Il pourrait sembler facile d'imaginer rapidement la reconnaissance vocale, à cause de la facilité dont nous, les êtres humains, pouvons effectuer la reconnaissance vocale des personnes qui parlent dans nos vies quotidiennes. Pourtant, comme nous l'avons mentionné plutôt, ce domaine a accumulé de nombreuses recherches au fil de ces trois dernières décennies. Le fait que ces recherches ont duré aussi longtemps prouve bien sa difficulté. Mais comme énoncé plutôt, la technologie n'a cessé d'avancer et a maintenant permis de rendre la reconnaissance bien plus accessible et compréhensible.

Notre objectif étant de créer une application de reconnaissance vocale, il est nécessaire de revoir certaines bases sur le sujet. Comme la notion de la « parole », beaucoup d'entre nous connaissent probablement déjà ce mot, mais peu d'entre nous savent comment elle est vraiment représentée dans notre technologie actuelle et pourquoi elle est aussi convoitée au point d'avoir eu droit à plusieurs dizaines d'années de recherches intensives à travers le monde.

2.2 Notion de la parole : [1] [2] [3] [10]

2.2.1 Point de vue populaire :

Du point de vue public, la parole est un son, produit par la corde vocale humaine, qui comporte plusieurs syllabes assemblées pour constituer un mot, ou bien une séquence de plusieurs mots formant une phrase. Les caractéristiques de la parole dépendent de beaucoup de facteurs liés au locuteur, notamment son sexe, sa nationalité, son timbre vocal, son accent...

2.2.2 Définition technique :

La majorité de la population a déjà vu la représentation de la parole dans nos technologies électroniques, dans nos téléphones en écoutant un enregistrement, par exemple ; mais peu ont vraiment compris le principe de cette représentation.

Voici un schéma de la représentation de la parole si l'on affichait cela sur notre écran d'ordinateur grâce à un éditeur de son :



Figure 2.01 Représentation de la parole dans le cadre de l'informatique

Nous avons probablement tous déjà vu ce type de schéma au moins une fois. Elle montre comment la parole est perçue par nos appareils électroniques ou nos ordinateurs.

En observant cette image, on se rend compte que cela ressemble à une courbe de signal sinusoïdale. Cette ressemblance n'en est, en fait, pas vraiment une, car la parole est vraiment un signal sinusoïdal qui possède ses amplitudes, sa fréquence et qui varie suivant l'unité de temps.

Si on plaçait des indications sur l'image précédente, on obtiendrait :




Figure 2.02 Représentation de la parole dans le cadre de l'informatique avec indications

Nous pouvons observer l'évolution du signal en fonction du temps sur le schéma.

La parole, tout comme tous les sons, est une vibration mécanique d'un fluide qui se propage sous forme d'ondes grâce à la déformation élastique de ce fluide (ou bien l'atmosphère). Les êtres humains, comme beaucoup d'animaux, ressentent cette vibration grâce à l'ouïe.

Il existe une science qui se nomme « l'acoustique » qui étudie en détail les caractéristiques du son. Ces images que nous avons vues précédemment sont, en fait, la représentation acoustique (analogique) d'une bande sonore.

C'est alors, ce signal analogique qui est reçu par l'ordinateur qui fera à son tour les traitements nécessaires à la bande sonore en fonction des besoins de l'utilisateur.

2.2.3 La perception de la parole :

Comme pour tous les phénomènes perçus, le temps et l'espace jouent un rôle fondamental dans la perception de la parole. La parole étant un son qui se propage dans l'espace au cours d'un temps, la relation entre temps, espace et la parole est donc évidente.

On distingue plusieurs caractères de la parole :

- La direction d'origine
- L'intensité, dites aussi volume sonore ou « sonie »
- La hauteur de tonalité
- Le timbre, qui comprend la variation caractéristique de l'émission sonore dans le temps

Il suffit qu'un de ces caractères varie, les autres restants inchangés, pour qu'on perçoive une différence. La répétition d'une forme dans le temps entraîne la notion de rythme. Par ailleurs, les êtres humains sont capables de distinguer et de suivre une voix avec certains caractères particuliers au milieu d'une quantité d'autres.

2.2.3.1 Intensité ou sonie :

L'impression d'une voix douce ou forte dépend principalement de la valeur de puissance que le locuteur émet dans sa parole. Dans le domaine de l'acoustique, l'intensité du son s'exprime souvent en décibels (dB). C'est une grandeur sans dimension, dix fois le logarithme décimal du rapport de puissance entre une grandeur caractéristique du son étudié et celle d'un son de référence. Un décibel correspond à peu près à la plus petite variation de volume sonore perceptible par un humain. Le niveau 0 dB correspond à un son pratiquement imperceptible.

Les décibels se réfèrent au logarithme décimal de la puissance. L'intensité acoustique est une puissance par mètre carré, donc multiplier l'intensité acoustique par 10, c'est augmenter le niveau sonore de 10 dB, la multiplier par 100, c'est augmenter le niveau de 20 dB, etc.

2.2.3.2 Fréquence et hauteur :

D'après les spécialistes en physiologie humaine, il est dit que l'être humain ne perçoit les sons que dans une plage de fréquence allant d'environ 16 Hz pour les fréquences basses ou graves à 15 à 18 KHz pour les aiguës les plus fines et élevées.

La sensibilité diminue progressivement aux fréquences extrêmes et varie selon les individus, la perception des aiguës diminue notamment avec l'âge, et celle des graves se confondant finalement avec celle des vibrations.

Par contre, les machines ou ordinateurs disposant de microphones, selon les fins auxquelles elles sont destinées (enregistrement d'ultrasons, d'infrasons, de voix normales, de voix d'animaux...), peuvent ne pas avoir de limites exactes en termes de perception de son. Ce qui fait, donc, que la qualité du microphone et son domaine d'utilisation influent beaucoup sur la qualité de la bande acoustique reçue par l'ordinateur en vue de la reconnaissance.

2.2.4 Spécificités de la parole :

2.2.4.1 Avantages du mode parole :

Si on prend comme référence le modèle humain, les avantages de la parole semblent aux premiers abords déterminants :

a) Naturel :

La parole constitue le mode le plus naturel de communication entre personnes humaines, du fait que son apprentissage s'effectue dès l'enfance, ce qui est loin d'être le cas pour la maîtrise de la frappe au clavier, par exemple.

b) Rapidité/efficacité :

Plusieurs études d'ergonomie montrent que le débit en parole spontanée est de l'ordre de 200 mots/minute à comparer aux 60 mots/minute d'un expert pour la frappe au clavier.

L'efficacité de la parole ne provient pas seulement de ce qu'elle permet un débit d'informations plus élevé que d'autres modes de communication, mais également de ce qu'elle peut être aisément utilisée en superposition avec ceux-ci. La parole laisse l'utilisateur libre de ses

mouvements : elle est donc particulièrement adaptée aux applications dans lesquelles il s'agit pour l'utilisateur de conduire plusieurs tâches simultanément, ou de contrôler des processus complexes qui monopolisent gestes et/ou vision.

Par ailleurs, d'un point de vue cognitif, la parole associée à des informations visuelles permet d'en améliorer la mémorisation ou de n'en souligner que le point saillant, ce qui est couramment utilisé dans l'enseignement interactif.

Cependant, si la parole présente un débit plus rapide pour l'émission d'un message par une machine ou une personne humaine, cet avantage ne se vérifie pas pour la perception humaine : la parole étant un phénomène séquentiel et monodimensionnel, l'écoute d'un message vocal (avec un débit de l'ordre de 200 mots/minute), nécessite un certain effort d'attention (du fait du caractère éphémère) et demande à l'utilisateur plus de temps que la lecture d'une page-écran (pour laquelle le débit peut atteindre jusqu'à 700 mots/minute). Ces résultats d'expérimentation proscrivent les longs messages de synthèse : il est en effet préférable d'afficher à l'écran un message dès qu'il dépasse une certaine longueur ou alors d'en produire une version condensée avec la synthèse vocale. Ceci démontre qu'un mode ne saurait se substituer directement à un autre sans une adaptation préalable de la présentation du message, même si le contenu reste inchangé.

c) Extension du champ d'action :

La parole permet d'avoir un accès immédiat à une information sans avoir à parcourir toute une arborescence hiérarchique de menus : il est toujours possible bien sûr d'utiliser des raccourcis clavier ou des langages de commande, mais la prononciation d'un seul mot peut remplacer jusqu'à une dizaine de commandes élémentaires effectuées à l'aide de touches fonctions ou de souris et représente ainsi un effort mnémotechnique moindre.

La parole permet également d'avoir accès à un objet non visible (sur l'écran, par exemple). À son pouvoir de désigner ou nommer des objets, s'ajoute la possibilité d'établir des échanges de niveau sémantique complexe et de manipuler des notions abstraites, ce qui peut contribuer à modifier, en l'enrichissant, le dialogue avec la machine. La suprématie de la parole est évidente pour des commandes incrémentales (déplacement pas-à-pas d'un objet sur l'écran), pour lesquelles tout mode de désignation (souris, manche à balai) reste plus efficace, dans la plupart des cas.

2.2.4.2 Limitations du mode parole :

Les avantages cités ci-dessus doivent être tempérés par le caractère intrinsèque de la parole, son extrême variabilité, qui représente une difficulté pour le traitement automatique : cette variabilité peut être liée soit au locuteur (état physique et cognitif), soit à l'environnement ou au média de transmission du signal, soit à la langue elle-même (ambiguïté). À cela s'ajoutent les contraintes imposées par les limitations technologiques (prise de son) et leur usage dans un contexte opérationnel.

a) Variabilité du signal due au locuteur :

Deux ou répétitions d'un même message par la même personne ne sont pas strictement identiques. Le signal se modifie en fonction de l'état émotionnel ou physique du locuteur (stress, fatigue, voix enrouée, etc.), mais également en fonction du style adopté (soigné ou relâché). Le décodage est d'autant plus complexe que le signal n'est pas affecté de façon linéaire par un ralentissement ou une accélération de débit, les parties stables des voyelles étant plus fortement modifiées que les parties consonantiques en élocution rapide. La variabilité interlocuteur (voix d'homme, de femme, ou d'enfant) est naturellement encore plus importante.

S'il est évidemment nécessaire de modéliser cette variabilité pour la reconnaissance, il est également indispensable d'en tenir compte pour la synthèse : par un phénomène inverse, lorsqu'une machine parle, la perception humaine habituée à une certaine variabilité (qui ne gêne en rien la compréhension) supporte mal d'entendre une voix artificielle possédant une prosodie par trop répétitive, par exemple.

b) Variabilité due à l'environnement acoustique :

Le microphone, selon les caractéristiques (plus ou moins directif), capte, en même temps que le signal de parole, les bruits de l'environnement. Les bruits non stationnaires sont bien sûr les perturbants pour la reconnaissance : à bord d'avions par exemple, le bruit de respiration du pilote dans son masque à oxygène peut être plus gênant que le bruit du moteur de l'avion.

c) Variabilité due au média de transmission :

Les lignes analogiques du réseau téléphonique, outre leur limitation en bande passante (300-3000 Hz), présentent de nombreuses distorsions (atténuation, écho, etc.) qui ne sont pas identiques de l'une à l'autre. Leur remplacement actuel par des lignes numériques facilite la reconnaissance de la parole par téléphone. La reconnaissance par radio téléphone (réseau

Itineris/GSM) présente encore plus de difficultés que par ligne analogique, du fait de la bande passante de 13 kHz, de la communication hertzienne et de la correction qui est numérique, ce qui devrait évoluer avec la norme GPRS.

d) Variabilité due à l'ambiguïté de la langue :

Il importe de modéliser finement les différents niveaux (lexiques, syntaxe sémantique, pragmatique) des connaissances qui concourent à l'interprétation du message. Le signal de la parole est un signal continu sans marque de pause entre les mots, ce qui nécessite la segmentation qui, du fait de la richesse lexicale, n'est pas déterministe. En raison du grand nombre d'homophones hétérographes (formes verbales, adjectivales, nominales, etc., de même prononciation, mais d'orthographe différente), la langue française se situe parmi les langues européennes les plus difficiles à segmenter en unités lexicales.

En outre, la parole est un phénomène qui se crée en temps réel : un discours spontané est de ce fait émaillé de nombreuses hésitations, reprises et autocorrections qui ne sont pas toujours compatibles avec les mots répertoriés dans le lexique ni avec la syntaxe de l'écrit.

Contrainte technologique de la prise de son :

Le capteur (microphone) pour être efficace est souvent intrusif dans la mesure où il peut nécessiter le port d'un serre-tête, ce qui est rédhibitoire pour le grand public. Une prise de son à l'aide de plusieurs microphones couplés peut alors s'avérer nécessaire afin de ne pas souffrir d'une baisse de performances.

e) Contraintes liées au contexte opérationnel :

La parole étant un mode naturel de communication, il importe de doter la machine de capacités lui permettant de faire la différence entre les mots de commande qui lui sont destinés, d'une part, et les commentaires qui s'adressent à un autre utilisateur, d'autre part. Ce problème de changement de contexte, commun à la reconnaissance du geste, est loin d'être réglé. Une autre contrainte est la non-confidentialité et la coupure par rapport au monde réel : même si on utilise un casque pour le retour vocal, le fait de parler à voix haute à la machine ne permet pas de garder les informations confidentielles et peut, de toute façon, gêner les autres utilisateurs par le bruit engendré. On connaît bien cet inconvénient avec les téléphones portables. Par ailleurs, le port d'un casque contribue à isoler l'utilisateur du monde extérieur.

f) Connaissances linguistiques ou machine Learning ?

Nous savons que les règles linguistiques qui couvrent une langue sont très nombreuses et dont certains sont plus complexes que d'autres. La dérivation et l'encodage des règles d'une langue entière requièrent donc beaucoup d'efforts. Donc pour pouvoir construire un simple modèle de paroles, il est nécessaire d'assembler une très grande masse de données. (Notamment des milliers d'heures d'enregistrements vocaux)

2.2.4.3 Typologie des systèmes commercialisés de reconnaissance liée » aux spécificités de la parole :

a) Prise de son :

Ainsi que cela a déjà été souligné, l'une des difficultés majeures de la reconnaissance de la parole est qu'elle nécessite l'utilisation d'une interface spécialisée, à savoir un microphone, susceptible de capter aussi bien le signal de parole que les bruits environnants. C'est pourquoi de meilleures performances sont obtenues avec un microphone directif ou de proximité, c'est-à-dire intégrées soit dans un casque ou serre-tête soit dans un combiné téléphonique. Mais dans de nombreuses applications, le système doit être intégré dans le poste de travail. Il est alors nécessaire de prendre en compte les caractéristiques sonores de l'environnement par un prétraitement (filtrage du bruit) ou par l'élaboration de modèle de bruit qui seront reconnues en même temps que le signal de parole. En voiture et sur les bornes de hall de gare, une antenne ou barrette de plusieurs microphones permet de mieux localiser le locuteur et d'extraire le signal de parole du bruit ambiant. Une autre caractéristique est de proposer un microphone soit ouvert (c'est-à-dire que la reconnaissance fonctionne en permanence), soit commandé manuellement (push-to-talk or push-to-activate) chaque fois que l'utilisateur s'adresse à la machine.

b) Type de langage :

Un langage peut être caractérisé par la taille de son vocabulaire et la complexité de sa syntaxe. En ce qui concerne la taille, on distingue les systèmes de reconnaissance à petit vocabulaire (quelques dizaines de mots), moyen (quelques centaines) ou grand (de plusieurs milliers à plusieurs centaines de milliers). De nombreuses applications ne nécessitent que quelques centaines de mots (pour un langage de commande, par exemple). En revanche, lorsqu'on aborde la dictée automatique, la taille peut rapidement dépasser plusieurs centaines de milliers de mots (qui sont en fait les formes fléchies, verbales, nominales, adjectivales d'une entrée lexicale) ; si

nécessaire, il est alors possible de partitionner le vocabulaire en plusieurs sous-vocabulaires. Dans ce cas, la taille du vocabulaire actif (c'est-à-dire connu par le système au moment de la reconnaissance) est seule significative. Pour les systèmes de dictée, ce vocabulaire est en général d'ordre de 60 000 mots pour un vocabulaire total de plus de 200 000. Grâce à une gestion dynamique des vocabulaires actifs et passifs, le vocabulaire peut être considéré comme illimité.

Afin de caractériser la complexité de la syntaxe, la mesure couramment employée est la perplexité (ou facteur de branchement dynamique). Cette mesure, fondée sur la théorie de la communication, indique le nombre moyen de mots candidats possibles après qu'un mot a été reconnu, et s'appuie sur un modèle de langage en l'absence duquel tous les mots sont équiprobables. La perplexité des langages professionnels, du type de ceux qui sont utilisés dans les rapports médicaux, par exemple, est généralement inférieure à 60, et le plus souvent de l'ordre de 10, alors que les langages utilisés dans des ouvrages littéraires (romans, comptes rendus de voyage) peuvent atteindre des perplexités de plusieurs centaines de mots.

La parole spontanée, qui ne respecte pas les règles de la grammaire écrite, présente une perplexité encore supérieure.

c) Types d'utilisateurs :

Deux catégories principales, grand public et professionnelles, peuvent être identifiées. Il convient encore de faire une distinction entre le novice et l'expert en fonction de la connaissance que l'utilisateur a du domaine d'application, d'une part, et entre l'utilisateur occasionnel et celui qui est habitué au fonctionnement du système, d'autre part. Dans de nombreuses applications destinées au grand public, telles que les serveurs vocaux ou les bornes de renseignement, il est difficile d'imposer un apprentissage aux utilisateurs. Il est alors préférable que les systèmes soient indépendants du locuteur (multilocuteurs). Pour les professionnels, afin de garantir de meilleures performances, les systèmes sont en général dépendants du locuteur (monolocuteurs) ; dans ce premier cas, un apprentissage au préalable est nécessaire pour tout nouveau locuteur. Jadis, les produits commercialisés imposaient à l'utilisateur de prononcer, souvent plusieurs fois de suite, la totalité du vocabulaire. Une telle contrainte n'est plus acceptable, dès lors que le vocabulaire dépasse plusieurs centaines de mots. Pour la reconnaissance de grands vocabulaires, cette phrase permet à la machine d'adapter ses modèles de référence acoustiques au locuteur à partir d'un ensemble de phrases représentatives des phonèmes d'une langue donnée. La machine modifie en même temps ses modèles linguistiques

et peut prendre en compte ainsi des façons de parler propres à ce locuteur ; pour la dictée automatique, les systèmes sont maintenant adoptifs en ligne, c'est-à-dire pendant l'utilisation réelle à chaque phrase prononcée par l'utilisateur, les modèles, tant acoustiques que linguistiques, sont, de manière implicite, automatiquement modifiés. Ainsi le taux de reconnaissance parfois désastreux au début, s'améliore sensiblement et rapidement. Cependant il est crucial que l'utilisateur ne laisse passer aucune erreur de reconnaissance pour ne pas compromettre l'apprentissage.

Selon ces trois principaux critères, il est possible d'identifier trois classes de systèmes actuellement commercialisés :

- Systèmes de reconnaissance de parole continue de petits vocabulaires (de quelques dizaines à quelques centaines de mots), monolocuteurs robustes au bruit, donc utilisables dans un environnement difficile soit par des professionnels, soit par le grand public : par exemple, les systèmes utilisés pour les tâches de contrôle de qualité ou de maintenance ou intégrés dans des voitures haut de gamme, tel celui de DaimlerChrysler qui permet la reconnaissance de 300 mots pour interroger l'ordinateur à bord ;
- Serveurs vocaux indépendants du locuteur, accessibles par téléphone pour le grand public, utilisé avec un vocabulaire pouvant varier de quelques dizaines à quelques milliers de mots, prononcés en mode isolé ou détecté dans le flot de paroles continue et spontanée : plusieurs systèmes sont opérationnels dès à présent pour des tâches bien définies (informations sur les horaires de trains, par exemple) aux États-Unis et en Europe ;
- Systèmes de dictée, monolocuteurs, adoptifs en ligne permettant la reconnaissance dans un environnement calme d'un vocabulaire de plusieurs centaines de milliers de mots, mais imposant le plus souvent à l'utilisateur professionnel une phrase d'apprentissage de plusieurs dizaines de minutes : de nombreux systèmes ont été commercialisés par IBM, Dragon Systems, Philips, etc.

2.3 Les étapes de la reconnaissance vocale : [8] [11] [12]

Il est important de noter que la reconnaissance vocale n'est pas seulement constituée de la reconnaissance en elle-même ; la reconnaissance vocale est, comme nous avons mentionné dans le chapitre précédent, subdivisée en deux parties : la reconnaissance et la synthèse.

Nous allons d'abord voir en quoi ces deux parties consistent :

2.3.1 La reconnaissance :

La reconnaissance regroupe plusieurs composants qui se complètent chacun pour former cette reconnaissance.

2.3.1.1 Le mot déclencheur ou Wake Word :

La toute première étape qui initie l'ensemble du processus de reconnaissance vocale s'appelle le mot clé déclencheur qui est traduit régulièrement par « wake word » en anglais. Le but principal de cette première technologie du cycle est d'activer par la voix l'écoute de l'utilisateur afin de relever la commande vocale qu'il souhaite réaliser.

Ici il s'agit littéralement de « réveiller » le système. Bien qu'il existe d'autres manières de procéder pour déclencher l'écoute, conserver l'utilisation de la voix tout au long du cycle est essentiel pour optimiser son utilisation. En effet, elle permet de proposer une expérience linéaire avec comme seule interface le vocal.

Le mot clé déclencheur comporte intrinsèquement plusieurs intérêts en ce qui concerne la conception d'assistants vocaux.

Dans notre contexte, une des principales craintes concernant la reconnaissance vocale réside dans la protection des données personnelles liée à l'enregistrement audio. Avec l'apparition récente du RGPD (Règlement Général sur la Protection des données), cette crainte à l'égard du respect de la vie privée et de l'intimité s'est encore amplifiée, poussant la création d'un traité l'encadrant.

C'est pour cela que le mot déclencheur est si important. En conditionnant la phase d'enregistrement de la voix par cette action, tant que le mot clé n'a pas été clairement identifié, rien n'est enregistré théoriquement. Oui, théoriquement, car selon la politique de l'entreprise vis-à-vis des données, tout est relatif. Pour se prémunir de cela, la reconnaissance embarquée (hors ligne) est une alternative.

Une fois l'activation confirmée, seules les phrases portant l'intention de l'action à réaliser seront enregistrées et analysées pour assurer le fonctionnement du cas d'usage.

2.3.1.2 La transcription de la voix en texte ou Speech To Text (STT) :

Une fois la reconnaissance vocale initiée grâce au mot déclencheur, il est nécessaire d'exploiter la voix. Pour cela, il est tout d'abord primordial de l'enregistrer et de la numériser avec une technologie de Speech To Text (aussi connue comme la reconnaissance automatique de la parole).

Durant cette étape, la voix est captée en fréquences sonores (sous forme de fichiers audio, à l'instar de la musique ou de tout autre bruit) pouvant être exploitées par la suite.

Selon l'environnement d'écoute, des pollutions sonores sont présentes ou non. Afin d'améliorer l'enregistrement de ces fréquences et donc par la même occasion leur fiabilité, différents traitements peuvent être opérés.

- La normalisation servant à supprimer les pics et les creux dans les fréquences afin d'harmoniser l'ensemble.
- La suppression des bruits de fond pour améliorer la qualité audio.
- La découpe des segments en phonèmes (qui sont des unités distinctives au sein des fréquences, exprimées en millième de seconde) permettant de distinguer les mots les uns des autres.

Les fréquences, une fois enregistrées, peuvent être analysées afin d'associer à chaque phonème un mot ou un groupe de mots pour constituer un texte. Cette étape peut être réalisée de différentes manières, mais une méthode en particulier constitue l'état de l'art aujourd'hui : le Machine Learning (Apprentissage Machine).

Une sous-partie de cette technologie s'appelle le Deep Learning : un algorithme recréant un réseau de neurones, capable d'analyser une quantité importante d'informations et de constituer une base de données répertoriant les associations entre les fréquences et les mots. Ainsi, chaque association va créer un neurone qui servira à déduire de nouvelles correspondances.

De ce fait, plus les informations sont nombreuses, plus le modèle est précis statistiquement parlant et capable de prendre en compte le contexte général pour attribuer le meilleur mot en fonction des autres déjà définis.

Limiter les erreurs du STT est essentiel pour obtenir l'information la plus fiable afin de procéder aux étapes suivantes.

La reconnaissance vocale recouvre tous les aspects liés à l'interprétation, par la machine, du langage humain. Dans ces applications de reconnaissance vocale, nous distinguerons les systèmes de commandes vocales et les systèmes de dictée.

2.3.1.3 Le NLP (Natural Language Processing), traduction du langage humain en langage machine :

Une fois les précédentes étapes effectuées, les données textuelles sont envoyées directement au module NLP (Natural Language Processing). Cette technologie a pour but principal d'analyser la phrase et d'en extraire un maximum de données linguistiques.

Pour ce faire, elle commence par associer des tags aux mots de la phrase, c'est ce que l'on appelle la *tokenisation*. Ce sont en réalité des « étiquettes » que l'on appose sur chaque mot afin de les caractériser. Par exemple, « Ouvre » sera défini comme le verbe définissant une action, « le » comme le déterminant un nom propre ou un COD, etc. et ce pour chacun des éléments de la phrase.

Dès que ces premiers éléments sont identifiés, il est nécessaire de donner du sens aux ordres issus de la reconnaissance vocale. C'est pourquoi deux analyses complémentaires sont effectuées.

Tout d'abord, l'analyse **syntactique** qui a pour but de modéliser la structure de la phrase ; puis, le modèle **sémantique** qui, une fois la nature et la position des mots trouvées, va tâcher de comprendre leur sens individuellement, mais également lorsqu'ils sont assemblés dans la phrase afin d'en traduire une intention générale de l'utilisateur. Nous détaillerons ces deux notions plus tard dans ce chapitre.

L'importance du NLP dans la reconnaissance vocale réside dans sa capacité à traduire les éléments textuels (soit les mots et phrases) en ordres normalisés, comprenant le sens et l'intention, pouvant être interprétés par l'intelligence artificielle associée et être réalisés.

2.3.1.4 L'intelligence artificielle :

En sachant que le titre du paragraphe principal est « les étapes de la reconnaissance vocale », il pourrait sembler illogique d'évoquer l'intelligence artificielle, pourtant, elle est bien une alliée nécessaire de la reconnaissance vocale.

Tout d'abord, l'intelligence artificielle, bien qu'intégrée dans le processus des précédentes technologies, n'est pas toujours indispensable pour réaliser les cas d'usages. En effet, si nous parlons de technologies connectées (donc Cloud), l'IA aura son utilité. D'autant plus que la complexité de certains cas d'usages, notamment sur les informations à corréler pour les produire, la rend obligatoire.

Par exemple, il est parfois nécessaire de confronter plusieurs informations avec des actions à réaliser, des intégrations de services extérieurs ou intérieurs ou des bases de données à consulter.

En d'autres termes, l'intelligence artificielle constitue le cas d'usage lui-même, l'action concrète qui va découler de l'interface vocale. Selon le contexte d'utilisation et la nature, de l'ordre, les éléments sollicités et les résultats donnés seront différents.

Prenons un cas concret. Vivoka a permis la création d'un casque de moto connecté qui permet d'utiliser des fonctionnalités avec la voix. Différents usages sont disponibles, comme l'utilisation du GPS ou de la musique.

La requête « Emmène-moi à une station-service sur le chemin » va renvoyer un ordre normalisé à l'intelligence artificielle avec l'intention de l'utilisateur :

- Contexte : Type de carburant du véhicule, préférence de prix (influe sur la distance à parcourir)
- Services externes : Appeler l'API du fournisseur de solution GPS
- Action à réaliser : Conserver le trajet actuel, rajouter une étape sur l'itinéraire.

Ici, l'intelligence utilisée par notre système va soumettre des informations et une requête à un service extérieur qui dispose d'une intelligence spécialisée pour nous renvoyer le résultat à opérer chez l'utilisateur.

L'IA est donc une pièce maîtresse dans de nombreuses situations. Cependant, pour des fonctionnalités embarquées (donc hors-ligne), les besoins sont moindres, se rapprochant plus de la réalisation de commandes simples comme la **navigation sur une interface** ou le **compte-rendu d'actions**. Il s'agit ici d'avoir des cas d'usages spécifiques qui ne nécessitent pas de consulter des informations multiples.

2.3.1.5 La reconnaissance du locuteur :

La reconnaissance du locuteur est, pour la plupart des applications créées pour tout public, une option facultative. La reconnaissance du locuteur, comme son nom l'indique, est l'identification et l'authentification de l'utilisateur du programme de reconnaissance vocale. L'utilité de la reconnaissance du locuteur réside principalement dans la notion de sécurité du programme, entre autres, le fait de ne permettre l'utilisation du programme qu'à un ou des utilisateurs préenregistrés en mémoire. Une des utilités de la reconnaissance du locuteur est la prédiction de plusieurs caractéristiques du locuteur (par exemple, son sexe, son âge, son accent, etc.) pour des usages divers selon les besoins de ou des utilisateurs.

2.3.2 La synthèse ou *Text To Speech (TTS)* :

La synthèse vocale, ou plus communément appelée Text To speech pour les spécialistes dans le domaine, comme son nom l'indique, est la synthétisation de paroles par un ordinateur pour qu'il puisse, à son tour, parler comme le ferait un être humain. La synthèse vocale peut être définie comme la communication de la machine à l'homme. Il correspond au feedback (retour) du système qui se manifeste à travers une voix synthétique. En réponse à l'utilisateur, il est nécessaire pour conserver la relation personne-machine.

La synthèse vocale est construite à partir de voix et de sons humains diversifiés selon la langue, le genre, l'âge ou l'humeur. Pour qu'un texte puisse être transformé en paroles pour une machine, il importe de découper le texte en morceaux correspondant de manière univoque à une unité de son. On conçoit facilement que si cette découpe se faisait, par exemple, au niveau des mots, il serait nécessaire de stocker en mémoire la prononciation de tous les mots d'une langue, ce qui n'est guère concevable. C'est la raison pour laquelle cette découpe se fait généralement au niveau des phonèmes, le texte étant ainsi « traduit » de façon phonétique. Un phonème correspond à la plus petite unité de la chaîne linguistique (sonore) qui peut être considérée comme unité distinctive sans être elle-même nécessairement significative, c'est un son élémentaire non ambigu.

Des modules de production du son (synthétiseurs) peuvent alors, sur la base de cette analyse, « lire » le texte. Cette technologie est aujourd’hui bien maîtrisée au niveau de la prononciation des mots. Au niveau des phrases, il reste encore pas mal de développements à réaliser pour obtenir une prosodie correcte, c’est-à-dire pour interpréter les phrases avec le ton, le timbre, le phrasé, le rythme et l’emphase qui caractérisent le langage humain ; les améliorations dans ce domaine nécessitent l’usage de dictionnaires, d’analyses grammaticales et sémantiques analogues à celles utilisées en reconnaissance vocale. Nous nous y attarderons plus loin.

Parmi les applications de la synthèse vocale, nous citerons :

- L’aide aux personnes handicapées : une personne privée de la parole peut par exemple communiquer par le téléphone avec un tiers en tapant son message sur PC qui peut le lire pour son correspondant, ou encore un malvoyant peut avoir un ordinateur qui lui lit des textes.
- L’interaction par téléphone avec une base de données de produits pour en obtenir une description ou avec une centrale d’aide en ligne ;
- Les bornes interactives à vocation touristique par exemple ;
- La possibilité de consulter son courrier électronique à distance via une communication téléphonique ;
- La possibilité d’inclure des messages vocaux dans des applications de bureautique ou dans des pages Internet.

2.4 Les systèmes de reconnaissances vocales : [4] [13] [14]

2.4.1 Les systèmes de commandes vocales :

Les applications de ce type permettent notamment à l’utilisateur de contrôler verbalement des équipements. Par complexité croissante, on peut classer ces systèmes en trois groupes :

2.4.1.1 Les systèmes à reconnaissance discrète :

Ce sont les applications où soit un nombre limité de mots soit de courtes phrases peuvent être utilisés pour commander le système. On y retrouve par exemple les applications téléphoniques où l’on peut choisir vocalement un point de menu (navigation interactive), le contrôle vocal des commandes de menus dans les logiciels (« fermer fichier, sortir »), certains logiciels de saisie automatique de données où les valeurs sont à choisir dans une liste limitée connue.

2.4.1.2 Les systèmes à reconnaissance « à la volée » :

Ces systèmes permettent à l'utilisateur de s'exprimer par des phrases, mais sont entraînés à repérer certains mots de la phrase, mots qui se trouvent dans son dictionnaire interne et sur lesquels ils basent leur action. La consultation d'un horaire de chemin de fer est un exemple de ce type de système : sur base de la phrase « je voudrais me rendre à Bruxelles à Paris lundi prochain », le système repérera « Bruxelles », « Paris » et « lundi » pour proposer l'horaire correspondant.

2.4.1.3 Les systèmes à reconnaissance continue :

On trouvera ici, les applications les plus avancées de commande vocale où l'on peut s'adresser au système en langage naturel. On trouvera des exemples dans les systèmes évolués de dictée où l'on pourra inclure des commandes vocales évoluées comme « souligner et mettre en gras le troisième mot de ce paragraphe ».

2.4.2 Les systèmes de dictée :

Les systèmes de dictée constituent le plus difficile à résoudre dans le domaine de la reconnaissance vocale. Comme pour les systèmes de commande vocale, les applications de dictée peuvent être divisées en plusieurs catégories en fonction de leur complexité :

2.4.2.1 Les systèmes à reconnaissance discrète :

On classe ici les systèmes où l'utilisateur doit parler avec de courtes poses entre chaque mot ; ce sont les premiers systèmes de dictée qui ont été développés dans les années quatre-vingt. Ces systèmes n'ont plus beaucoup de succès aujourd'hui étant donné les progrès accomplis dans la dictée continue.

2.4.2.2 Les systèmes à reconnaissance continue :

C'est la « quête du Graal » des chercheurs en reconnaissance vocale : permettre à un utilisateur de dicter son texte à l'ordinateur, de façon continue, avec un vocabulaire riche, à une vitesse de locution normale et avec une reconnaissance proche de 100 %. C'est à ce type de système que nous nous intéressons dans la suite.

2.5 Les systèmes de dictée continue : théorie et technologie : [4] [13]

Que l'on veuille utiliser la reconnaissance vocale pour composer un numéro de téléphone, naviguer parmi les fenêtres sur un PC, entrer des données dans un logiciel ou dicter une lettre dans un traitement de texte, le problème de base reste le même : **identifier le sens d'un flux de paroles** prononcées souvent dans un bruit de fond plus ou moins important.

Comme nous l'avons vu dans le chapitre précédent, cette tâche est rendue difficile non seulement par les déformations induites par l'usage d'un micro, mais aussi par une série de facteurs inhérents au langage humain, comme les homonymes, les accents locaux, les habitudes du langage, les différences de vitesse entre locuteurs, les imperfections d'un micro, etc.. Or pour notre oreille humaine, ces facteurs ne représentent généralement pas de difficultés. Notre cerveau jongle avec ces déformations de la parole en prenant en compte, quasi inconsciemment, des éléments non verbaux et contextuels qui nous permettent de lever les ambiguïtés.

Ce n'est qu'en prenant en compte ces éléments extérieurs au son proprement dit que les logiciels de reconnaissance vocale pourront atteindre des degrés élevés de fiabilité.

Aujourd'hui, les logiciels de reconnaissance vocale qui donnent les meilleurs résultats sont tous basés sur une approche probabiliste.

Le but de la reconnaissance vocale est de reconstituer une séquence de mots m à partir d'un signal acoustique enregistré A .

Dans l'approche statistique, on va considérer toutes les suites de mots M qui pourraient correspondre au signal A . Dans cet ensemble de suites possibles, on choisira alors celle ($\bar{M}$) qui est la plus probable, c'est-à-dire celle qui maximise la probabilité $P(M/A)$ que M soit l'interprétation correcte de A , ce que l'on notera :

$$\bar{M} = \arg_M \max P(M/A) \quad (2.01)$$




Figure 2.1 Représentation du processus de reconnaissance vocale

L'axiome de Bayes permet de réécrire l'expression précédente :

$$\bar{M} = \arg_M \max \frac{P(A/M)P(M)}{P(A)} \quad (2.02)$$

Et comme $P(A)$ est une constante dans la recherche du meilleur M , on a finalement :

$$\bar{\bar{M}} = \arg_M \max P(A/M)P(M) \quad (2.03)$$

Cette dernière équation est la clé de l'approche probabiliste de la reconnaissance vocale. En effet, le premier terme $P(A/M)$ représente la probabilité d'observer le signal acoustique A si la séquence de mots M a été prononcée : c'est un problème purement acoustique ; le second terme $P(M)$ représente la probabilité que ce soit la suite de mots M qui a été effectivement énoncée : c'est un problème de nature linguistique. L'équation ci-dessus nous enseigne donc que l'on peut scinder le problème de reconnaissance vocale en deux parties indépendantes : on modélisera séparément les aspects acoustiques et les problèmes linguistiques. Dans la littérature, on parle généralement d'orthogonalité entre les modèles acoustiques et les modèles linguistiques.

2.5.1 Le modèle acoustique :

Le modèle acoustique est basé sur la notion de phonèmes. Les phonèmes peuvent être considérés comme les unités sonores de base dans le langage verbal. Le premier stade de la reconnaissance vocale est de reconnaître un ensemble de phonèmes dans un flux de paroles : Le signal de la parole (capté à l'aide d'un micro) est d'abord digitalisé : il est échantillonné par une transformation de Fourier qui calcule les niveaux d'énergie du signal par bandes de 25 millisecondes, bandes qui se recouvrent entre elles de 10 millisecondes (valeurs typiques).

La fréquence d'échantillonnage doit être au moins égale au double de la fréquence maximale du signal à numériser ; la voix couvre environ la bande de 60 Hz à 10 kHz. Le résultat est comparé avec des prototypes stockés en mémoire de l'ordinateur à la fois dans un dictionnaire standard et dans un dictionnaire propre au locuteur.

Ce dernier dictionnaire est construit au départ par des séances de dictée de textes standards que le locuteur doit effectuer avant d'utiliser efficacement le logiciel. Ce dictionnaire propre est régulièrement enrichi par autoapprentissage lors des utilisations du logiciel.

Il est intéressant de noter que l'empreinte vocale ainsi constituée est relativement stable pour un locuteur donné et peu influencé par certains facteurs extérieurs comme le stress, le rhume...




Figure 2.02 Représentation synoptique du fonctionnement global du modèle acoustique dans le cadre des systèmes de dictée continue

2.5.2 Le modèle linguistique :

On scinde généralement en deux la partie liée au langage : une partie syntaxique et une partie sémantique.

Lorsque le modèle acoustique a identifié au mieux les phonèmes « entendus », il faut encore rechercher le message $\bar{M}$ Le plus probable qui y correspond, c'est-à-dire la probabilité $P(M)$ définie plus haut. C'est le rôle des modèles syntaxique et sémantique.




Figure 2.03 Représentation synoptique du fonctionnement global du modèle linguistique dans le cadre des systèmes de dictée continue

À partir de l'ensemble des phonèmes issus du modèle acoustique, le modèle syntaxique va assembler les phonèmes en mots. Ce travail se fait également sur base d'un dictionnaire et d'une grammaire standards ainsi que d'un dictionnaire et d'une grammaire propres au locuteur ; ces derniers tiennent compte des « habitudes » du locuteur et s'enrichissent continûment.

Ensuite, le modèle sémantique cherche à optimiser l'identification du message par une analyse du contexte des mots et en se basant à la fois sur une sémantique courante propre à la langue et sur une sémantique (un style) propre au locuteur. Cette sémantique propre s'enrichira au fur et à mesure de l'utilisation du logiciel ; la plupart des logiciels permettent également de l'enrichir par l'analyse de textes qui reflètent les habitudes stylistiques du locuteur.

Ces deux modules travaillent de pair et on conçoit facilement qu'il existe un feedback entre eux initialement, les dictionnaires liés à ces deux modules étaient basés sur des modèles de langages à syntaxe fixe, c'est-à-dire sur une grammaire définie par un ensemble rigide de règles.

Ensuite, les logiciels de reconnaissance vocale ont évolué vers l'utilisation de modèles probabilistes locaux : la reconnaissance ne s'effectue plus au niveau d'un mot, mais au niveau d'une suite de mots, appelée n-Gram où n représente la longueur en mots d'une séquence. Si l'on considère l'exemple simple du mot « passé », on lui attribuera deux étiquettes grammaticales possibles auxquelles on attachera une probabilité lexicale qui rend compte de leur usage en français : (NOM, probabilité = 0.7) et (PARTICIPE PASSE, probabilité = 0.3). Si l'on analyse ce mot non pas seul, mais dans son contexte (par exemple dans un diGram), le fait qu'il soit précédé d'une forme fléchie de l'auxiliaire être renforcera la probabilité de l'étiquette PARTICIPE PASSE.

n-gram : c'est le terme utilisé pour décrire une séquence de n mots. Un diGram (2-gram), par exemple, est une séquence composée de 2 mots ; un triGram (3-gram) en est une composée de 3 mots.

Les statistiques de ces modèles sont obtenues à partir de textes types et peuvent s'enrichir progressivement. Ici aussi ce sont les modèles de Markov cachés qui sont utilisés pour décrire les aspects probabilistes.

Actuellement, les logiciels les plus évolués tendent à combiner les avantages des modèles statistiques et des modèles à syntaxe fixe dans ce que l'on nomme les « grammaires probabilistes », l'idée étant de dériver à partir de grammaires fixes des probabilités pouvant être combinées avec celles d'un modèle probabiliste. Dans ces dernières approches, il devient

difficile de distinguer le modèle syntaxique du modèle sémantique et l'on parle plutôt d'un seul modèle linguistique.

2.6 L'état actuel et l'avenir de la technologie : [4]

Les systèmes de reconnaissance vocale ont fait d'importants progrès ces dernières années. Ces progrès ont pu être réalisés grâce aux recherches sur les modèles acoustiques et linguistiques, mais aussi grâce à la croissance continue de la puissance des processeurs. Cet accroissement de puissance a non seulement permis de tirer le maximum de profits des algorithmes utilisés, mais également de pouvoir exécuter les logiciels de reconnaissance vocale sur les configurations actuelles des PC, ce qui a ouvert un très large marché et, par conséquent, incité au développement de la recherche.

Aujourd'hui, les systèmes fonctionnels sont basés sur une approche statistique. Les leaders du marché proposent généralement des logiciels de reconnaissance du langage continu avec des possibilités de commandes pour les fonctions courantes des applications de traitement de texte. Ils annoncent des tailles vocabulaires allant de 30 000 à 60 000 mots par langue, en permettant des dictées à la vitesse de 120 à 160 mots par minute (ce qui correspond à un débit de paroles relativement élevé) et avec un succès de reconnaissance supérieur à 95 %.

Parallèlement au vocabulaire courant, certains fournisseurs proposent des dictionnaires propres à certaines catégories professionnelles : médecins, juristes, financiers.

La plupart des logiciels actuels sont dépendants du locuteur, ce qui nécessite un apprentissage initial qui peut varier sensiblement d'un constructeur à l'autre. Pratiquement tous les bons logiciels permettent l'amélioration de cet apprentissage au fur et à mesure de leur utilisation.

La recherche dans le domaine de la reconnaissance vocale reste très active et il y a encore beaucoup de défis à relever afin d'améliorer les performances futures :

- Améliorer les modèles acoustiques qui aujourd'hui sont encore fort influencés par les conditions externes telle la position du micro, le fond sonore ambiant...
- Améliorer les modèles linguistiques : nous avons déjà parlé plus haut des recherches en matière de « grammaire probabiliste » ; des recherches sont également entreprises pour utiliser simultanément différentes approches comme les techniques statistiques et les réseaux neuronaux.

- Rendre les modèles indépendants du locuteur : des recherches dans ce sens sont effectuées afin de construire des modèles valables pour une large classe de population (par exemple : toutes les personnes dont l'anglais est la langue maternelle) ; cela permettrait de supprimer les phases d'apprentissage. En pratique, on tend vers un compromis qui permettrait au locuteur de se passer de l'apprentissage initial tout en améliorant la reconnaissance au cours du temps.

2.7 Conclusion :

De ce que nous avons vu au long du ce chapitre, la maîtrise complète de la parole nous permettrait de nombreux privilèges qui faciliteraient grandement notre vie quotidienne. Pourtant la marche vers cette maîtrise totale est encore loin d'être parcourue à cause des nombreuses difficultés dont ce domaine a fait face depuis sa création. Mais ce n'est pas que pour autant qui aura empêché la technologie d'évoluer, car la reconnaissance vocale est déjà omniprésente de nos jours et la preuve de cela sera le projet de traitement de texte par commande vocale que nous allons détailler dans le chapitre suivant.

CHAPITRE 3

APPLICATION VOCALE NOTE

3.1 Introduction :

Nous arrivons dans le chapitre où nous allons développer les détails de la programmation du logiciel de traitement de texte par commandes vocales grâce à la reconnaissance vocale. Pour programmer le logiciel, le langage utilisé est le langage **Python** et nous verrons tout au long de ce chapitre comment, grâce à ce langage, l'application a pu être développée.

3.2 Cahier de charge :

Le projet « Vocale Note », qui signifie littéralement « Note vocale », consiste à permettre à l'utilisateur de créer, d'ouvrir et de modifier un fichier texte comme le ferait un simple logiciel « Notepad », mais à la différence, vocale note implémente la reconnaissance vocale qui permettra à l'utilisateur de ce dernier de dicter son texte directement sans taper au clavier et de commander vocalement les traitements de textes inclus dans le programme (gras, italique, alignement, police et la taille de police, etc.).

Le but principal de l'application est de montrer l'une des utilités de la reconnaissance vocale, de montrer son fonctionnement et de prouver son importance dans l'évolution de la technologie numérique. Nous verrons en détail plus tard les détails concernant les principales fonctionnalités de l'application.

3.3 Choix des outils :

3.3.1 Pourquoi le langage Python ?

Étant donné le grand nombre de langages de programmation qui existe actuellement, cette question est tout à fait logique. Plusieurs facteurs influent sur le choix d'un langage de programmation :

3.3.1.1 Temps d'exécution :

Lorsqu'il s'agit de développer une application complexe contenant plusieurs codes sources et plusieurs milliers de lignes de codes par fichier, le temps d'exécution de chaque code source doit être assez court pour une meilleure satisfaction sur le programme. Avoir plusieurs codes sources contenant chacun des milliers de lignes de codes implique plusieurs exécutions de chaque code source pour la vérification de son fonctionnement ; donc, avoir un temps

d'exécution relativement lente pourrait engendrer une insatisfaction et un mécontentement lors de plusieurs tests de code source successifs.

En général, ce temps de réponse varie de 0.5 seconde à 6 secondes en fonction de la complexité et de la taille du code source, mais aussi de la puissance du microprocesseur. Mais dans certains cas où le microprocesseur est relativement faible, ce temps d'exécution peut atteindre les 10 à 15 secondes pour chaque code source à exécuter.

C'est là que le langage Python se démarque des autres langages de programmation, car le langage Python, par rapport à Java ou C par exemple, est plus rapide dans son temps d'exécution.

3.3.1.2 Programmation orientée objet :

Comme beaucoup de langages de programmation actuels, le langage Python permet la programmation orientée objet, qui est une caractéristique qui fait du langage un langage très puissant.

3.3.1.3 Langage de haut niveau :

Le langage est un langage de haut niveau qui rend la lecture du code source bien plus facile grâce aux mots clés se rapprochant beaucoup du langage humain, même si par rapport à d'autres langages comme Java, Python offre une trop grande facilité et peut rendre certains erreurs anodins, d'habitude, fatales pour le programme. (Comme les espaces, les indentations,...)

3.3.1.4 Présence de la librairie Pocketsphinx :

La librairie chargée de la reconnaissance vocale que nous utilisons se nomme « Pocketsphinx » qui est présent dans C mais aussi dans Python, et est la version portable de Sphinx. En fait, la Pocketsphinx offre une très grande rapidité de décodage par rapport à sa version non portable or Pocketsphinx n'est opérationnel que dans certains langages de programmation dont Python, ce qui a décidé donc du choix du langage. Si par exemple, nous aurions utilisé Java, seul Sphinx serait disponible et l'application serait incroyablement lente à traiter par l'ordinateur.

3.3.2 Sublime Text :

Pour développer vocal note, nous avons utilisé l'IDE connu sous le nom Sublime Text, un outil puissant, facile à utiliser, plus confortable, et surtout, qui prend en charge presque tous les langages de programmation dont Python inclus. Sublime Text offre aussi une très grande

rapidité de lancement par rapport à d'autres éditeurs comme Eclipse, Jupyter Notebook (Anaconda)....

3.3.3 Pourquoi Pocketsphinx ?

Il existe de nombreuses bibliothèques de reconnaissances vocales pour python, dont : Pocketsphinx, Vosk, Speech Recognition.... Et dont la performance de chacune varie selon le mode d'entraînement, les données et des modèles (acoustique, linguistique et dictionnaire phonétique). Nous utilisons pocketsphinx, car elle offre une manipulation de programme et des modèles plus faciles et ainsi faciliter les changements dans sa configuration.

3.4 Mode d'emploi :

Dans ce paragraphe, nous allons parler du mode d'emploi des différentes fonctionnalités de l'application en général.

3.4.1 Initiation :

Nous avons sûrement déjà vu ou utilisé un logiciel ou une application de traitement de texte. Comme son nom l'indique, ce type d'application se spécialise dans le domaine des fichiers textes ; le logiciel Microsoft Office Word, Notepad de Microsoft sont de parfaits exemples de logiciels de traitement de texte. Mais Vocal Note, comparée à Notepad, par exemple, offre une meilleure interface graphique et des fonctionnalités supplémentaires qui font toute la différence. Voici des images comparatives des deux logiciels :




Figure 3.01 Image de Notepad




Figure 3.02 Capture de l'application Vocal Note

De ces deux images, nous pouvons distinctement voir la différence flagrante de complexité et de design qu'il y a entre ces deux logiciels.

Comme énoncé précédemment, notre application concerne le traitement de texte, mais elle ne sera pas aussi complexe que Microsoft Word, le but principal étant de montrer le fonctionnement de la reconnaissance vocale au niveau d'une application de traitement de texte, nous allons donc rester sur un logiciel de traitement de texte très basique comme Notepad de Windows.

3.4.2 Traitement de texte :

L'interface de Vocal note a été développée de façon à ce que l'utilisateur comprenne vite comment utiliser l'application, des icônes illustratives ont été utilisées pour que l'utilisateur reconnaisse sans trop grande difficulté la fonction d'un des composants.

Revoyons encore une fois l'application, mais cette fois, nous allons mettre des indications pour illustrer le fonctionnement des différents composants :




Figure 3.03 Image de l'application Vocal Note avec indications

3.4.2.1 Groupe : « Gestion de fichiers »

Ce groupe, comme son nom l'indique, est chargé de la gestion du fichier texte à créer. Notamment :

a) *Bouton « créer fichier » :*

Ferme le fichier en cours et crée un nouveau fichier : Untitled



Figure 3.03 Bouton « Nouveau fichier » ou « New File »

b) *Bouton « Ouvrir fichier » :*

Ouvre une fenêtre d'ouverture de fichier texte et affiche le contenu du fichier ouvert dans l'application une fois le fichier choisi.



Figure 3.04 Bouton « Open fichier » ou « Open File »




Figure 3.05 Bouton « Nouveau fichier » ou « New File »

c) Bouton « Enregistrer fichier » ou « Save file » :

Ouvre une fenêtre de sauvegarde de fichier si le fichier n’a pas encore été sauvegardé et met à jour le fichier ce dernier a déjà été sauvegardé dans un répertoire.



Figure 3.06 Bouton « Enregistrer fichier » ou « Save File »




Figure 3.05 Bouton « Nouveau fichier » ou « New File »

d) Bouton « Supprimer fichier » :

Ferme le fichier actuel et supprimer le fichier dans son répertoire.



Figure 3.06 Bouton « Supprimer fichier » ou « Supprimer File »

3.4.2.2 Groupe « Presse papier » :

Ce groupe s'occupe de la gestion de la presse papier du système.

a) Bouton « Coller » :

Colle le texte de la presse papier (équivalent de : Ctrl + V)




Figure 3.07 Bouton « Coller » ou « Paste »

b) Bouton « Couper » :

Coupe le texte sélectionné vers la presse papier (équivalent de la commande : Ctrl + X)



Figure 3.08 Bouton « Couper » ou « Cut »

c) Bouton « Copier » :

Copie le texte sélectionné vers la presse papier (équivalent de la commande : Ctrl + C)



Figure 3.09 Bouton « Copier » ou « Copy »

3.4.2.3 Groupe « Style de texte » :

Ce groupe prend en charge les traitements de texte suivant : style de police, taille de police, gras (bold), italique (italic), alignement (gauche, centré, droite) et réinitialiser. Il n'est pas nécessaire de préciser lequel des boutons effectue chaque action, car les icônes parlent d'elles-mêmes avec l'image ci-dessous.




Figure 3.10 Groupe « Style de texte »

3.4.3 Commande et reconnaissance vocale :

Il y a deux modes de reconnaissance vocale de Vocal note : le mode dicté ou « Dictation » et le mode commande ou « Command ».

Pour changer de mode il suffit de cliquer sur l'un des boutons « C » (Commande) et « D »(Dictée) dans l'application.



Figure 3.11 Boutons de choix de mode

3.4.3.1 Mode dictée ou « Dictation mode »:

Ici, le nom prend tout son sens, il s'agit simplement du mode où la reconnaissance transcrit les mots dictés en texte qui sera inséré dans la zone de texte de l'application sans prendre en compte la signification des mots dictés. Le micro coloré en vert indique que la reconnaissance est en mode dictée.




Figure 3.12 Mode dictée ou « Dictation mode »

3.4.3.2 Mode commande ou « Command mode » :

Dans ce mode, les paroles de l'utilisateur sont transcrites à l'application pour que ce dernier effectue la commande énoncée par l'utilisateur. Par exemple, si l'utilisateur dit : « SET BOLD » alors l'application mettra en gras le texte.

Le mode commande est caractérisé par l'image suivante, dont le micro coloré en bleu :




Figure 3.13 Mode commande ou « Command mode »

Voici la liste des commandes implémentées dans l'application : (les multiples commandes sont séparées par « / »)

Commandes	Méthode appelée	Action
NEW FILE	newFile()	Nouveau fichier
OPEN FILE	openFile()	Ouvrir fichier
DELETE FILE	deleteFile()	Supprimer fichier
SAVE FILE	saveFile()	Enregistrer fichier
SAVE AS	saveFileAs()	Enregistrer fichier sous

COPY/COPY IT		copy()	Effectuer la commande : Ctrl + C
CUT/CUT IT		cut()	Effectuer la commande : Ctrl + X
PASTE/PASTE IT		paste()	Effectuer la commande : Ctrl + V
SET POLICE/ POLICE	LOMA	setFamilyLoma()	Style de police : « Loma »
	ANI	setFamilyAni()	Style de police : « Ani »
	NORASI	setFamilyNorasi()	Style de police : « Norasi »
	SERIF	setFamilySerif()	Style de police : « Serif »
	DIALOG	setFamilyDialog()	Style de police : « Dialog »
SET SIZE/ SIZE	TINY	setSizeTiny()	Taille de police : « Minuscule »
	SMALL	setSizeSmall()	Taille de police : « Petit »
	MEDIUM	setSizeMedium()	Taille de police : « Moyen »
	BIG	setSizeBig()	Taille de police : « Grand »
	GIANT	setSizeGiant()	Taille de police : « Très grand »
SET BOLD/SET BOLDED/ SET BOLD STYLE/SET BOLDED STYLE		setBoldMenu()	Mettre au gras
SET ITALIC/ITALIC STYLE/ SET ITALIC STYLE		setItalicMenu()	Mettre en Italique

SET NORMAL/NORMAL STYLE/ SET NORMAL STYLE		setNormalMenu()	Désactiver gras et italique
SET BOTH/SET BOLD ITALIC/ SET BOLD ITALIC STYLE/SET B AND I		setBothMenu()	Mettre en Gras Italique
RESET/ RESET STYLE		Reset()	Réinitialiser style du texte
SELECT ALL		selectAll()	Sélectionner tout
SET ALIGNMENT/ ALIGN	LEFT	alignLeft()	Aligner le texte à gauche
	CENTER	alignCenter()	Centrer le texte
	RIGHT	alignRight()	Aligner le texte à droite
GET HELP/OPEN HELP/ OPEN DOCUMENTATION USER MANUAL		showDocs()	Ouvrir mode d'emploi de l'application
SET THEME/THEME	BREEZE	setThemeBreeze()	Thème de l'application : Breeze
	ADAPTA	setThemeAdapta()	Thème de l'application : Adapta
	SCIDGREY	setThemeScid()	Thème de l'application : Scidgrey
COMMANDS LIST/ LIST COMMANDS		showComs()	Montrer la liste des commandes
SHOW ABOUT		showAbout()	Montrer informations Personnelles
CLOSE THE QUIT THE EXIT THE	APPLICATION	exit()	Fermer le programme
	PROGRAM		

Tableau 3.01 : Liste des commandes de l'application Vocal note

3.5 Implémentation de la reconnaissance vocale :

Nous voilà maintenant dans l'objet principal du projet, la partie la plus difficile dans le développement de l'application vocal note. Il s'agit d'assigner des commandes vocales aux fonctionnalités de l'application de traitement de texte grâce à une bibliothèque de programmation particulière, Pocketsphinx de CMU.

3.5.1 À propos de la bibliothèque de reconnaissance vocale Pocketsphinx :

Pocketsphinx est une bibliothèque de reconnaissance vocale disponible pour quelques langages de programmation comme : Android Java, Python, C/C++.... Elle permet au développeur d'utiliser de la reconnaissance vocale dans ses programmes. C'est un API ouvert au public et facile à prendre en main pour les développeurs déjà habitués à leur langage.

Pocketsphinx nécessite certaines bibliothèques pour fonctionner correctement :

- Sphinxbase : Bibliothèque contenant les scripts de base nécessaires au fonctionnement de pocketsphinx
- Pocketsphinx : Bibliothèque contenant le cœur de pocketsphinx
- Sphinxtrain : utilisé par pocketsphinx pour l'entraînement des modèles

3.5.2 Les configurations des programmes pocketsphinx

Dans toutes les applications de reconnaissance vocales, pas seulement pour ceux utilisant pocketsphinx, il est nécessaire d'établir certaines configurations pour que la reconnaissance puisse démarrer. Ces configurations sont : le modèle acoustique, le modèle linguistique et le dictionnaire phonétique. Nous avons déjà mentionné deux de ces configurations précédemment de façon théorique, mais ici, nous allons découvrir ces configurations de la manière pratique en les utilisant directement dans la programmation.

3.5.2.1 Le modèle acoustique ou « acoustic model »:

Rappelons d'abord que le modèle acoustique se base sur la reconnaissance des phonèmes dans le flux de paroles du locuteur. Le flux audio de paroles capté par le microphone est constitué de phonèmes qui sont propres à un langage précis utilisé par le locuteur et aussi propres au locuteur lui-même. Par exemple, le mot « Hello » en le découpant en phonèmes se basant sur la prononciation anglaise donne « H EY L OW ».




Figure 3.14 : Découpage du mot « Hello » en phonèmes

Dans notre cas, nous allons utiliser un modèle de la langue anglaise qui scannerá donc des phonèmes de la langue anglaise.

Voici quelques exemples de phonèmes pour la prononciation de l’alphabet anglaise :

A	B	C	D	E	F	G	H	I	J
AH/EY	B IY	S IY	D IY	IY	EH F	JH IY	EY CH	AY	JH EY
K	L	M	N	O	P	Q	R	S	T
K EY	EH L	EH M	EH N	OW	P IY	K Y UW	AA R	EH S	T IY
U	V	X	Y	Z	W				
Y UW	V IY	EH K S	W AY	Z IY	D AH B AH L Y UW				

Tableau 3.02 : Exemple de phonèmes pour l’alphabet anglaise

Grâce au modèle acoustique, le programme sera capable, en comparant le flux de paroles avec le modèle acoustique, d’identifier les phonèmes, qui est une étape cruciale au déroulement de la reconnaissance.

Pour notre programme, nous utiliserons le modèle acoustique adaptée « en-us-adapt » qui est la version adaptée du modèle anglais par défaut de pocketsphinx « en-us ».

Dans la configuration de pocketsphinx alors, nous devons mettre dans « config » le paramètre :

-hmm et lui donner comme valeur, le chemin du modèle acoustique à utiliser :

```
-hmm /home/yukari/Python-workspace/Vocal_note/models/en-us-adapt
```

Ce modèle contient les phonèmes de base de l'anglais et des données acoustiques pour la conversion de flux audio en phonèmes.

Adaptation du modèle acoustique par défaut :

Certes, *pocketsphinx* offre un modèle acoustique plus ou moins opérationnel pour la reconnaissance de la langue anglaise, mais ce modèle n'est pas efficace à 100 % pour autant. Or notre programme nécessite une précision assez élevée pour l'exécution de commandes, il faut donc adapter le modèle à l'utilisation du programme pour optimiser sa précision. Il est à noter que l'adaptation n'adapte pas nécessairement pour un locuteur en particulier, elle insère juste les données d'adaptations au modèle de base pour augmenter la précision de la reconnaissance pour un programme particulier.

Pour adapter un modèle acoustique, il nous faut des données d'adaptations. Ces données sont des fichiers audio (.wav) qui contiennent les phrases et mots fréquemment utilisés dans l'application pour que la précision soit la plus optimale possible.

Il nous faudra donc un dossier *adaptation_data* contenant toutes les données audio d'adaptation, ainsi que deux fichiers : *adaptation_data.fileids* et *adaptation_data.transcription* qui sont des fichiers textes.

- *adaptation_data.fileids* : contient le nom de toutes les données d'adaptation (fichiers « .wav ») à adapter au modèle.
- *adaptation_data.transcription* : contient les phrases ou mots qui correspondent aux données d'adaptation.

Par exemple si nous voulons adapter un modèle « model » pour les phrases « SET BOLD » et « SET ITALIC », le répertoire « adaptation » devrait contenir :

```
adaptation_data.fileids  
adaptation_data.transcription  
adaptation_data_01.wav  
adaptation_data_02.wav
```

Dont *adaptation_data.fileids* contiendra :

```
adaptation_data_01  
adaptation_data_02
```

Et *adaptation_data.transcription* contiendra :

```
<s> SET BOLD </s> (adaptation_data_01)  
<s> SET ITALIC </s> (adaptation_data_02)
```

Donc pour notre application *Vocal_note*, l'adaptation s'est fait avec des données vocales de chaque commande (voir tableau 3.01 page 50 – 52) dans un répertoire *commands_adapt* et ainsi générer le modèle adapté « en-us-adapt » que notre programme de reconnaissance utilisera.

3.5.2.2 Le modèle linguistique ou « langage model »:

Le modèle linguistique, comme nous l'avons énoncé dans le précédent chapitre, est le modèle chargé de l'assemblage des phonèmes identifiés par le modèle acoustique en mots ou groupe de mots clairs.

Exemple :




Figure 3.15 : Rôle du modèle linguistique

En pratique, on crée le modèle linguistique manuellement pour imposer une restriction à la reconnaissance et augmenter la probabilité des mots fréquemment utilisés dans le programme pour éviter les erreurs de commandes.

Dans notre cas, le programme étant un programme de traitement de texte, il est donc plus probable que l'utilisateur dise des commandes de traitement de texte comme « SET BOLD » au lieu de mots peu probables tels que : « EXPLODE », « ANIMAL ».....

Grâce au modèle linguistique, notre application sera plus en mesure de décoder les commandes de traitements de textes que d'autres commandes non implémentées dans l'application et la

précision de la reconnaissance se verra augmenter drastiquement que si le modèle linguistique incluait tous les mots du dictionnaire anglais.

Le modèle linguistique est un fichier texte avec l'extension (.lm).

Pour montrer de façon plus explicite le concept, voici un schéma illustratif :




Figure 3.16 : Différence entre modèle linguistique restreint et modèle linguistique vaste

Avec un modèle linguistique trop vaste, les mots de prononciations proches seraient très vite confondus par le programme et engendreraient une basse précision de la reconnaissance.

Pour configurer le modèle linguistique de pocketsphinx à notre modèle linguistique personnel, il suffit d'insérer dans la configuration la valeur de « -lm » qui sera le chemin du fichier modèle linguistique :

```
-lm /home/yukari/Python-workspace/Vocal_note/models/7520.lm
```

7520.lm est notre fichier de modèle linguistique pour l'application Vocal note.

3.5.2.3 Le dictionnaire de phonèmes :

Un dictionnaire de phonème contient la gestion de phonèmes pour les mots utilisés dans le programme. Il est utilisé pour spécifier la ou les prononciations de chaque mot du programme. Même si cela ne semble pas sauter aux yeux, ce n'est pas la même fonction que le modèle linguistique. Le dictionnaire spécifie la prononciation et le modèle linguistique assemble les mots en fonction de ces prononciations.

Un dictionnaire de phonème est aussi à générer personnellement en fonction du programme. Il est généré parallèlement au modèle linguistique, les deux étant dépendants.

En guise d'exemple pour le dictionnaire :

Si la prononciation par défaut de « BOLD » est : B OW L D pour l'accent maternel, on pourrait modifier cela avec le dictionnaire pour : B AH L D, par exemple.

Pour ajouter un dictionnaire à la configuration de pocketsphinx, il suffit, comme les deux modèles précédents, de spécifier à son paramètre, le chemin du dictionnaire

```
-dict /home/yukari/Python-workspace/Vocal_note/models/7520.dic
```

Et dont 7520.dic est le dictionnaire pour notre application Vocal note.

Il est utile de noter que ne pas spécifier ces configurations à pocketsphinx fait utiliser automatiquement à ce dernier, les valeurs par défauts. Par exemple, si l'on ne spécifie pas le modèle acoustique, pocketsphinx utilisera automatiquement le modèle acoustique par défaut.

3.5.3 La reconnaissance en temps réel de pocketsphinx ou LiveSpeech :

Il est à noter que la classe `ps_inMic()` de chargée de la reconnaissance se trouve dans le fichier `pocketsphinx_inmic.py`

3.5.3.1 Initialisation de LiveSpeech :

Il est évident que notre programme nécessite la reconnaissance vocale en temps réel, car elle capture en continu les paroles de l'utilisateur pour effectuer ses commandes, si le programme est en mode « commande » et de transcrire ses paroles en texte si en mode « dictée ».

La classe LiveSpeech de pocketsphinx permet justement d'effectuer cette écoute en temps réel pour capturer les mots de l'utilisateur. Les configurations dont nous avons parlé plus tôt sont données à cette classe pour que cette dernière effectue la reconnaissance en fonction de ces configurations.

LiveSpeech utilisera donc notre modèle acoustique adapté « en-us-adapt », le modèle linguistique « 7520.lm » et le dictionnaire de phonèmes « 7520.dic » pour notre application.

Voici la portion de code qui configure la reconnaissance en temps réel :

```
self.__speech=LiveSpeech(  
    lm="/home/yukari/Downloads/Python-  
workspace/Vocal_note/models/7520.lm",  
    dict="/home/yukari/Downloads/Python-  
workspace/Vocal_note/models/7520.dic",
```

```
hmm="/home/yukari/Downloads/Python-  
workspace/Vocal_note/models/en-us-adapt",  
buffer_size=1048, sampling_rate=16000  
)
```

Notre code pour la reconnaissance se trouve dans sa propre classe spécialisée dans la reconnaissance, ce qui explique la présence du mot clé « *Self*. ».

Nous pouvons voir dans le code les trois paramètres de configurations dont nous avons parlé précédemment, mais aussi deux autres paramètres :

- Buffer size : qui est la taille de mémoire tampon utilisée par la reconnaissance qui reçoit temporairement les données vocales.
- Sampling rate : c'est la fréquence d'échantillonnage de la piste vocale, elle doit impérativement être 16kHz pour le bon fonctionnement de la reconnaissance

3.5.3.2 Résultats de reconnaissance en temps réel :

a) La boucle de reconnaissance :

Dans la classe *ps_inMic()* se trouve la méthode *reco_loop()* qui est une boucle qui lit le résultat de la reconnaissance par LiveSpeech.

```
def reco_loop(self):  
    for phrase in self.__speech:  
        output = str(phrase)  
        self.queue.enqueue(output)
```

À chaque fois que l'utilisateur parle, la variable *phrase* prend la valeur de la parole reconnue par la reconnaissance en temps réel, puis la fonction *enqueue(output)* retourne la valeur de la phrase reconnue.

b) Traitement en parallèle :

Il est bien à noter que la reconnaissance vocale doit toujours être fonctionnelle tant que la fenêtre est encore ouverte, or la gestion d'interface et la gestion de reconnaissance vocale sont tous deux des boucles. Ce qui fait que lancer l'une d'elles stopperait l'autre et empêcherait le fonctionnement de l'application. Il faut donc introduire un traitement en parallèle de ces deux boucles.

Un traitement s'occupe de la gestion de l'interface, pendant que l'autre traitement effectue la reconnaissance vocale.

En mettant la gestion d'interface en traitement principal et la gestion de reconnaissance en traitement secondaire, nous atteignons l'objectif du parallélisme.

```
if __name__=='__main__':  
    print("Starting the program")  
    window = tk.Tk()  
    interface = Interface(window)  
    proc_queue = nbq()  
    sphinx = ps(proc_queue)  
    sphinx_proc = th(target = sphinx.reco_loop, daemon = True)  
    sphinx_proc.start()
```

Voici la portion de code qui se charge de séparer les deux traitements pour les traiter parallèlement.

```
Sphinx_proc = th(target= sphinx.reco_loop, daemon = True)
```

Cette ligne de code crée un nouveau traitement pour sphinx qui est une instance de la classe de reconnaissance vocale que nous avons vue précédemment qui sera lancée par la méthode *start()*

Nous pouvons remarquer un autre élément, *proc_queue = nbq()*, c'est une instanciation de la classe *NonBlockQueue()* dans le fichier *nonblockqueue.py* qui a été abrégée en tant que *nbq*. Le rôle de cette classe est de lier le traitement de l'interface et le traitement de reconnaissance vocales pour que ces deux traitements puissent s'échanger la valeur cruciale au fonctionnement du programme, la *phrase* détectée et reconnue par la reconnaissance en fonction de laquelle, les différentes fonctions (listées dans le tableau 3.01 page 50 – 52) seront lancées ou non.

d) Boucle de commande vocale :

La boucle qui effectue les fonctions correspondantes aux commandes énoncées ressemble à ceci :

```
while(1):  
    try:  
        msg = proc_queue.dequeue()  
        if(msg):  
            if interface.commandMode.get()==True:  
                if msg== « SET BOLD » :  
                    interface.setBoldMenu()
```

else :

```
interface.workspace.insert(tk.END, msg)
```

Si l'application est en mode commande, on teste la valeur de « msg » qui est la phrase reconnue si elle correspond à une des commandes de l'application, si oui, l'application exécute la fonction correspondante à cette commande. Par exemple, ici si la « msg » correspond à « SET BOLD » alors l'application lance la méthode `setBoldMenu()` de l'interface pour mettre le texte au gras.




Figure 3.17 : Image de résultat pour commande « SET BOLD »

Si l'application est en mode dictée, ce dernier va simplement écrire dans la zone de texte tout ce que l'utilisateur dira. (C'est le mode dicté qui a écrit le texte dans la zone de texte dans l'image ci-dessus)

3.6 Conclusion :

Développer une application de traitement de texte par commande vocale n'est donc pas très compliqué à notre époque, car de nombreux outils sont toujours créés pour faciliter cela. Pour développer l'interface, il suffit d'avoir la bibliothèque de l'interface, pour implémenter la reconnaissance, il suffit d'avoir `pocketsphinx`, `sphinxbase` et `sphinxtrain`. La plus grande difficulté de la programmation de Vocal note réside dans la liaison de l'interface graphique à la reconnaissance vocale par moyen de traitements en parallèle et dans l'adaptation du modèle acoustique pour l'optimiser à l'application Vocal note.

CONCLUSION GENERALE

Il est vrai qu'il était difficile d'imaginer pouvoir commander des programmes ou des ordinateurs par la voix au début, notamment, à cause de la complexité du sujet, surtout, dans la reconnaissance de la parole en continu. Mais ce temps est désormais révolu, car depuis toutes ces années où l'informatique et l'électronique évoluaient, la reconnaissance vocale a, elle aussi, gagné considérablement en puissance, et a fait d'incommensurables progrès pendant ce temps. Même si se faire comprendre par son ordinateur par l'unique moyen de la voie était farfelu à l'époque, cela n'a pas empêché les chercheurs scientifiques et informatiques de relever le défi et à chercher des moyens, théoriques et pratiques, pour espérer s'approcher de la reconnaissance totale de la parole par l'ordinateur.

Et grâce à ces recherches, de nombreux algorithmes et bibliothèques de reconnaissances vocales ont vu le jour, dont l'efficacité évolue de jour en jour grâce à l'évolution des partages d'informations dans le monde. Plus le temps évolue, plus la quantité de données dans le monde augmente et donc, plus l'efficacité de ces bibliothèques de reconnaissance vocale augmente, ces derniers se nourrissant de ces données.

Avec cette évolution phénoménale de la reconnaissance vocale, est-ce qu'envisager un programme complètement intelligent pouvant interagir de façon la plus humaine à son environnement et de comprendre parfaitement son entourage serait aussi farfelue qu'envisager la reconnaissance vocale comme à l'époque ?

ANNEXES

1. Code source de classe reconnaissance vocale : `pocketsphinx_inmic.py`

```
from pocketsphinx import LiveSpeech
import nonblock_queue

class ps_inMic:
    def __init__(self,queue):

        self.__speech=LiveSpeech(
            lm="/home/yukari/Downloads/Python-
workspace/Vocal_note/models/7520.lm",
            dict="/home/yukari/Downloads/Python-
workspace/Vocal_note/models/7520.dic",
            hmm="/home/yukari/Downloads/Python-
workspace/Vocal_note/models//en-us-adapt",
            verbose=True, no_search=False, full_utt=False,
            buffer_size=1048,sampling_rate=16000
        )
        self.queue = queue

    def reco_loop(self):
        for phrase in self.__speech:
            output = str(phrase)
            self.queue.enqueue(output)
```

2. Code source de la classe de queue : `nonblock_queue.py`

```
import queue

class NonBlockQueue:
    def __init__(self, size = None):
        if(size !=None):
            self.__blk_queue = queue.Queue(maxsize=size)
        else:
            self.__blk_queue = queue.Queue()

    def enqueue(self,msg):
        self.__blk_queue.put(msg)

    def dequeue(self):
        ret = None
        try:
            ret = self.__blk_queue.get(False)
        except queue.Empty:
            pass
        return ret
```

3. Code source la classe d'arrêt de traitement : `stoppablethread.py`

```
import threading

class StoppableThread(threading.Thread):
    def __init__(self,*args,**kwargs):
        super(StoppableThread, self).__init__(*args,**kwargs)
        self._stop_event = threading.Event()

    def stop(self):
        self._stop_event.set()

    def stopped(self):
        return self._stop_event.is_set()
```

4. Code source principal de l'application : main.py

```
#Bibliothèques nécessaires
from stoppablethread import StoppableThread as th
from pocketsphinx_inmic import ps_inMic as ps
from nonblock_queue import NonBlockQueue as nbq
from interface import Interface
import tkinter as tk
import time

if __name__=='__main__':
    print("Starting the program")
    window = tk.Tk()
    interface = Interface(window)
    proc_queue = nbq()
    sphinx = ps(proc_queue)
    sphinx_proc = th(target = sphinx.reco_loop, daemon = True)
    sphinx_proc.start()
    while(1):
        try:
            msg = proc_queue.dequeue()
            if(msg):
                if interface.commandMode.get()==True:
                    if msg == "NEW FILE":
                        interface.newFile()
                    if msg == "OPEN FILE":
                        interface.opentFile()
                    if msg == "SAVE FILE":
                        interface.saveFile()
                    if msg == "SAVE FILE AS":
                        interface.saveFileAs()
```

```

        if msg == "DELETE FILE":
            interface.deleteFile()

        if msg == "CLOSE APPLICATION" or msg ==
"CLOSE THE PROGRAM":
            interface.exit()

        if msg == "CLOSE THE APPLICATION" or msg ==
"CLOSE PROGRAM":
            interface.exit()

        if msg == "EXIT THE APPLICATION" or msg ==
"EXIT THE PROGRAM":
            interface.exit()

        if msg == "EXIT APPLICATION" or msg == "EXIT
PROGRAM":
            interface.exit()

        if msg=="SET BOLD" or msg=="SET BOLDED" or
msg=="SET BOLD STYLE" or msg=="BOLD STYLE":
            interface.boldValue.set('roman')
            interface.setBoldMenu()

        if msg=="SET ITALIC" or msg=="SET ITALIC
STYLE" or msg=="ITALIC STYLE":
            interface.italicValue.set('roman')
            interface.setItalicMenu()

        if msg=="SET NORMAL" or msg=="SET NORMAL
STYLE" or msg=="NORMAL STYLE" or msg=="NORMAL":
            interface.setNormalMenu()

        if msg=="SET BOLD ITALIC" or msg=="SET
BOTH" or msg=="SET B AND I" or msg=="SET ITALIC BOLD":
            interface.boldValue.set('roman')
            interface.italicValue.set('roman')
            interface.setBothMenu()

```

if msg=="BOLD ITALIC" or msg=="BOLD ITALIC
STYLE":

```
interface.boldValue.set('roman')  
interface.italicValue.set('roman')  
interface.setBothMenu()
```

if msg=="SET ALIGNMENT LEFT" or
msg=="ALIGNMENT LEFT" or msg=="ALIGN LEFT":

```
interface.alignLeft()
```

if msg=="SET ALIGNMENT RIGHT" or
msg=="ALIGNMENT RIGHT" or msg=="ALIGN RIGHT":

```
interface.alignRight()
```

if msg=="SET ALIGNMENT CENTER" or
msg=="ALIGNMENT CENTER" or msg=="ALIGN CENTER":

```
interface.alignCenter()
```

if msg=="SET POLICE LOMA" or msg=="POLICE
LOMA":

```
interface.setFamilyLoma()
```

if msg=="SET POLICE ANI" or msg=="POLICE
ANI":

```
interface.setFamilyAni()
```

if msg=="SET POLICE NORASI" or msg=="POLICE
NORASI":

```
interface.setFamilyNorasi()
```

if msg=="SET POLICE SERIF" or msg=="POLICE
SERIF":

```
interface.setFamilySerif()
```

if msg=="SET POLICE DIALOG" or msg=="POLICE
DIALOG":

```
interface.setFamilyDialog()
```

```

if msg=="SET POLICE UBUNTU" or
msg=="POLICE UBUNTU":

    interface.setFamilyUbuntu()

if msg=="SET SIZE TINY" or msg=="SIZE TINY":
    interface.setSizeTiny()
if msg=="SET SIZE SMALL" or msg=="SIZE
SMALL":

    interface.setSizeSmall()

if msg=="SET SIZE MEDIUM" or msg=="SIZE
MEDIUM":

    interface.setSizeMedium()
if msg=="SET SIZE BIG" or msg=="SIZE BIG":
    interface.setSizeBig()
if msg=="SET SIZE GIANT" or msg=="SIZE
GIANT":

    interface.setSizeGiant()

if msg=="COPY" or msg=="COPY IT":
    interface.copy()
if msg=="CUT" or msg=="CUT IT":
    interface.cut()
if msg=="PASTE" or msg=="PASTE IT":
    interface.paste()

if msg=="RESET" or msg=="RESET STYLE":
    interface.reset()

if msg=="GET HELP" or msg=="SHOW
DOCUMENTATION" or msg=="DOCUMENTATION" or msg=="USER MANUAL":
    interface.showDocs()

```

```

        if msg=="SHOW ABOUT":
            interface.showAbout()

        if msg=="COMMANDS LIST" or msg=="LIST
COMMANDS":
            interface.listCommands()

        if msg == "SELECT ALL":
            interface.selectAll()

        if msg=="THEME BREEZE" or msg=="SET THEME
BREEZE":
            interface.setBreeze()

        if msg=="THEME ADAPTA" or msg=="SET
THEME ADAPTA":
            interface.setAdapta()

        if msg=="THEME SCIDGREY" or msg=="SET
THEME SCIDGREY":
            interface.setScid()

        if msg == "UNDO":
            interface.undo()

        if msg == "REDO":
            interface.redo()

        interface.result.set(msg)
    else:
        interface.workspace.insert(tk.END," " + msg)
    window.update_idletasks()
    window.update()
    time.sleep(0.1)
except:
    exit(0)

```


BIBLIOGRAPHIE

- [1] F. N. W. Minker, «Développement des technologies vocales,» [En ligne].
- [2] J. a. Martin, Speech and Language Processing, 2008.
- [3] R. a. Hain, Speech Recognition, Computational Linguistics and Natural Language Processing Handbook, 2010.
- [4] SmalS-MvM, «La reconnaissance vocale - smals,» [En ligne]. Available: <https://www.smals.be/sites/default/files/assets/techno29-fr.pdf>.
- [5] M. J. Leboeuf, «Reconnaissanc et synthèse de la parole, Principales applications,» 2000. [En ligne]. Available: <http://www.centrcn.unmontreal.ca/-leboeufm/blt6134/application.html>.
- [6] L. L. W. M. A. C. G. Chollet, "Reconnaissance et compréhension de la parole: évaluation et applications", EBSI, Université de Montréal, 2000.
- [7] «Reconnaissance vocale - Définition et explications,» [En ligne]. Available: <https://www.techno-science.net/glossaire-définition/Reconnaissance-vocale.html>.
- [8] «Reconnaissanc vocale: fonctionnement et composition,» 25 Février 2021. [En ligne]. Available: <https://vivoka.com/reconnaissance-vocale-fonctionnement-composition>. [Accès le Mai 2021].
- [9] Hervé, «Petite histoire de la reconnaissance,» 2012. [En ligne]. Available: <https://www.abavala.com/petite-histoire-de-la-reconnaissance-vocale/amp/>. [Accès le 2021].
- [10] J. Poitou, «Reconnaissance et synthèse vocales,» 2017. [En ligne]. Available: <http://j.poitou.free.fr/vocal>. [Accès le Mai 2021].
- [11] A. CHAPUZET, «Reconnaissanc vocale: comment ça marche?,» 2 décembre 2019. [En ligne]. Available: [https://fr.linkedin.com/pulse/reconnaissance-vocale-comment%C3%A7a-marche-avec vivoca-aur%C3%A9lien-chapuzet](https://fr.linkedin.com/pulse/reconnaissance-vocale-comment%C3%A7a-marche-avec-vivoca-aur%C3%A9lien-chapuzet). [Accès le Juin 2021].
- [12] I. C. Education, «What is speech recognition ?,» 2 Septembre 2020. [En ligne]. Available: <https://www.ibm.com/cloud/learn/speech-recognition>.
- [13] D. J. SLFD1, «La dictée vocale,» [En ligne]. Available: <https://mu haz.org/la-dictée-vocale.html>.

- [14] D. Y. a. L. Deng, Automatic Speech Recognition, Microsoft Reseaarch, 2015.
- [15] «La Reconnaissance vocale,» [En ligne]. Available:
<http://deptinfo.unice.fr/twiki/pub/Linfo/PlanningDesSoutenances20032004/Benguigui-Ismails-Hamdan.pdf>.

RENSEIGNEMENTS

Nom : MAHEFA

Prénom : Harinianja

Adresse de l'auteur : Ambodivona Alakamisy Fenoarivo

Tél : 0345606995

Titre de mémoire : LA RECONNAISSANCE VOCALE : VOCAL NOTE

Nombre de pages : 67

Nombre de figures : 24

Nombre de tableaux : 2

Mots clés : Reconnaissance, données vocales, modèles

Directeur de mémoire : RANDRIARIJONA Lucien Elino

RESUME

La reconnaissance est connu comme l'équivalent de l' « oreille » des ordinateurs, qui leur permet d'écouter, de comprendre son utilisateur sans autres outils que la voix de ce dernier.

Les algorithmes de reconnaissance vocale ont besoin de s'alimenter en données spécifiques de paroles pour pouvoir établir les modèles de reconnaissances qui permettront au programme de reconnaître des mots ou séquences de mots énoncé par l'utilisateur et ainsi agir en fonction de ces derniers. Plus les programmes de reconnaissance vocale reçoivent de données vocales, plus précis ils seront.

ABSTRACT

The speech recognition is known as the « ear » of computers, which allows them to understand the user without any tools except his voice.

Speech recognition algorithms need specifics voice data for creating speech recognition models which can allow programs to decode the user's words and then, follows his order. More the data speech recognition programs collect, and then more the recognition will be accurate.